

Evolução Diferencial (ED) Differential Evolution (DE)

Métodos Computacionais **Inspirados na Natureza**
(MCIN)


Beatriz de S. Leite Pires de Lima
Rogério Espindola
Solange Guimarães

1

Differential Evolution (DE) Evolução Diferencial (ED)

Criado por,

- Storn, R., Price, K.V.: Differential evolution - a simple and efficient adaptive scheme for global optimization over continuous spaces (1995) **Technical Report** TR-95-012, ICSI (International Computer Science Institute, Berkeley)
- Storn, R., Price, K.V., Differential evolution - a simple and efficient heuristic for global optimization over continuous spaces, **Journal of Global Optimization** 11: 341–359, 1997.



2

Differential Evolution (DE)

- **Code for Continuous Function Optimization (an algorithm by Kenneth Price and Rainer Storn)**
- C, C++, Fortran, MatLab, Python, R, Java, Maple, Pascal, etc.
- Há muitas variantes com códigos disponíveis na web (especialmente no site GitHub)

3

Differential Evolution (DE)

Como em qualquer algoritmo evolutivo,


- Funções de custo não-lineares, não diferenciáveis e multimodais.
- Passível de paralelização.
- DE tem poucas variáveis de controle.
- Boas propriedades de convergência.

4

4

DE - Introdução

- Algoritmo estocástico de otimização populacional
- Desenvolvido inicialmente para minimizar (maximizar) funções contínuas reais (variáveis reais).



5

DE - Representação e População

- DE originariamente foi implementada para usar representação vetorial de numeros reais
- Pode ser empregada também para problemas inteiros ou binários, talvez perdendo eficiência
- DE originalmente não é geracional: o vetor decendente melhor avaliado imediatamente substitui o vetor de origem (pai) mais fraco.

6

DE - Notação e Representação

- Problema de **D** dimensões
- População de **N** indivíduos
- **G** designa geração
- Indivíduo i , definido como vetor $\mathbf{x}_{i,G}$, de variáveis:

$$\mathbf{x}_{i,G} = (x_{1i,G}, x_{2i,G}, x_{3i,G}, \dots, x_{ji,G}, \dots, x_{Di,G})$$

$$\forall j = 1, D$$

7

DE Clássico - População inicial

- Conjunto aleatório de vetores candidatos sorteados dentro dos limites do espaço de busca (sorteio com distribuição uniforme no espaço de busca);
- Tamanho mínimo da população, na forma clássica do DE, é 4 (um vetor de origem (pai) + 3 outros vetores para formar o vetor tentativa).

8

DE Básico - Pseudo Código Geracional

```

DE(N,CR,F,D,  $Popx_G$ )
Inicialize a população com N indivíduos
Enquanto o critério de parada não for atingido, faça,
    Para cada indivíduo da população,  $x_{i,G}$ , faça,
        Cria vetor tentativa ( $Popx_G, i, F, CR, u_{i,G+1}$ )
        Se  $f(u_{i,G+1}) < f(x_{i,G})$ ,
            então  $x_{i,G+1} = u_{i,G+1}$ 
            se não,  $x_{i,G+1} = x_{i,G}$ 
        end se
    end para
    G=G+1
end enquanto
End

```

Onde ,
F – peso diferencial, real > 0
CR – probabilidade de recombinação

Selecção determinística

9

DE Clássico - Pseudo Código Não Geracional

```

DE(N,CR,F,D,  $Popx$  )
Inicialize a população com N indivíduos
Enquanto o critério de parada não for atingido, faça,
    Para cada indivíduo da população,  $x_i$ , faça,
        Cria vetor tentativa ( $Popx, i, F, CR, u_i$ )
        Se  $f(u_i) < f(x_i)$ ,
            então  $x_i = u_i$ 
            se não,  $x_i = x_i$ 
        end se
    end para
end enquanto
End

```

Selecção determinística

10

DE - Vetor tentativa

Calculado em duas operações:

- Operador **mutação**:

Cria um **vetor mutante**, $\mathbf{v}_{i,G+1}$

- Operador “**crossover**”:

Determina o **vetor tentativa**, $\mathbf{u}_{i,G+1}$
através do cruzamento do vetor mutante, $\mathbf{v}_{i,G+1}$,
com o vetor do indivíduo, $\mathbf{x}_{i,G}$.

11

DE - Operadores

12

12

DE - Mutação Diferencial

Operador Mutação: cria vetor mutante, $v_{i,G+1}$

$$v_{i,G+1} = x_{base} + F(x_{r2,G} - x_{r3,G})$$

Onde,

$$x_{base} = x_{r1,G} \quad (\text{escolha aleatória dentre } N \text{ indivíduos})$$

ou

Risco de
convergência
prematura

$$x_{base} = x_{best,G} \quad (\text{melhor vetor})$$

$F = \text{fator ou peso diferencial}$

13

DE - Crossover “Binomial”

Operador crossover: determina o vetor tentativa $u_{i,G+1}$

$$u_{j,i,G+1} = \begin{cases} v_{j,i,G+1} & \text{se } randj \leq CR \text{ ou } j = rand(i) \\ x_{j,i,G} & \text{se } randj > CR \text{ e } j \neq rand(i) \end{cases}$$

Onde,

- $rand(i) \in [1, D]$ é um numero inteiro escolhido aleatoriamente;
- $randj \sim U(0,1)$ é um numero aleatório com distribuição uniforme;
- $CR \in [0,1]$ é um valor predefinido (parâmetro de controle) de crossover entre 0 e 1.

O termo $j = rand(i)$, garante que pelo menos 1 variável de $u_{i,G+1}$ será cruzada.

A grande maioria das publicações usa este Crossover, considerado o mais eficiente

14

DE - Crossover “Exponencial”

(Não muito usado)

$$u_{ji,G+1} = \begin{cases} v_{ji,G+1} & \text{se no intervalo de } L \text{ variáveis, iniciando em } k \\ x_{ji,G} & \text{otherwise} \end{cases}$$


Onde,

$k, L \in [1, D]$ são números inteiros escolhidos aleatoriamente

O processo é **circular**, iniciando na variável k e terminando $(L - 1)$ variáveis depois, na variável $(k + L - 1)$ – se ultrapassar D variáveis reinicia a contagem na variável 1 (**circular**).

15

DE - Ilustração da criação do Vetor Mutante



Fonte: Storn, R., Price, K.V (1997)

16

DE - Variantes comuns

$$\mathbf{v}_{i,G+1} = \mathbf{x}_{base} + F(\mathbf{x}_{r2,G} - \mathbf{x}_{r3,G}) + F(\mathbf{x}_{r4,G} - \mathbf{x}_{r5,G})$$

DE/x/y/z

onde,

x – vetor base a ser mutado: **rand** or **best**

y – número de diferenças randômicas na perturbação do vetor base

z – esquema de cruzamento: **binomial** ou **exponencial**

DE/best/2/bin $\mathbf{v}_{i,G+1} = \mathbf{x}_{best} + F(\mathbf{x}_{r1,G} - \mathbf{x}_{r2,G}) + F(\mathbf{x}_{r3,G} - \mathbf{x}_{r4,G})$

DE/rand/1/Bin $\mathbf{v}_{i,G+1} = \mathbf{x}_{r1,G} + F(\mathbf{x}_{r2,G} - \mathbf{x}_{r3,G})$

17

DE – Variantes Mutaç o

DE/current-to-best/1/bin

$$\mathbf{v}_{i,G+1} = \mathbf{x}_{i,G} + F(\mathbf{x}_{best,G} - \mathbf{x}_{i,G}) + F(\mathbf{x}_{r1,G} - \mathbf{x}_{r2,G})$$

Este termo comp e o
vetor base

DE/current-to-pbest/1/bin

$$\mathbf{v}_{i,G+1} = \mathbf{x}_{i,G} + F(\mathbf{x}_{pbest,G} - \mathbf{x}_{i,G}) + F(\mathbf{x}_{r1,G} - \mathbf{x}_{r2,G})$$

(sorteia dentre as p% melhores solu  es)

18

DE - Pseudo Código

```

DE(N,CR,F, i, Pop $x_G$ )
Inicialize a população com N indivíduos
Enquanto o critério de parada não for atingido, faça,
    Para cada indivíduo da população,  $x_{i,G}$ , faça,
        Cria vetor tentativa (Pop $x_G$ ,  $i$ ,  $F$ ,  $CR$ ,  $u_{i,G+1}$ )
        Se  $f(u_{i,G+1}) < f(x_{i,G})$ ,
            então  $x_{i,G+1} = u_{i,G+1}$ 
            se não,  $x_{i,G+1} = x_{i,G}$ 
        end se
    end para
end enquanto
End
  
```

Onde ,

F – fator real > 0

CR – probabilidade de recombinação

19

DE - Pseudo Código do Vetor *Trial* Binomial

```

Cria vetor tentativa (Pop $x_G$ ,  $i$ ,  $F$ ,  $CR$ ,  $u_{i,G+1}$ )
Selecione aleatoriamente 3 indivíduos da população:  $x_{r1,G}$ ,  $x_{r2,G}$ ,  $x_{r3,G}$ 
Sorteie uma posição  $rand(i)$ , [1,D]
Calcule vetor mutante:
     $v_{i,G+1} = x_{r1,G} + F(x_{r2,G} - x_{r3,G})$  - mutação
Determine vetor tentativa:
    para cada elemento  $j$  do vetor tentativa,  $u_{i,G+1}$ ,
        Sorteie numero randômico  $rand_j \sim U(0,1)$  – “crossover”
        Se  $rand_j \leq CR$  (ou  $j = rand(i)$ ),
            então,  $u_{ji,G+1} = v_{ji,G+1}$ 
            se não,  $u_{ji,G+1} = x_{ji,G}$ 
        fim se
    fim do para
Retorne  $u_{i,G+1}$ 
  
```

Onde ,

F – peso diferencial real > 0

CR – probabilidade de “crossover”

20

DE - Tratamentos de problemas

- Vetor sai do espaço de busca definido pelos limites laterais
 - Volta a variável para o contorno (limite lateral mais próximo da variável)
 - Gera aleatoriamente outra variável
 - Volta a variável para valor da iteração anterior
 - Gera outro vetor novo
 - Espelha o vetor ou variável para dentro do espaço viável
 - etc
- Evitar convergência prematura
 - Espalhar bem a população inicial
 - Opposition DE
 - Evitar base “best”
 - Etc..

Lembrete problemas com restrição - indivíduo inviável tem tratamento semelhante para todos os algoritmos evolutivos: penalizar a avaliação/aptidão, descartar, reparar, etc...

21

Resultados – Funções Storn & Price (1997)

11 Hyper-Ellipsoid

$$f_{11}(x) = \sum_{j=1}^D j^2 \cdot x_j^2; \quad \text{IPR: } x_j \in [-1, 1] \quad (26)$$

The global minimum is $f_{11}(0) = 0$ and the VTR was set to $1 \cdot e^{-10}$.

12 Katsuura's Function

$$f_{12}(x) = \prod_{j=1}^D \left(1 + j \cdot \sum_{k=0}^{\beta} \left| 2^k \cdot x_j - \text{nint}(2^k \cdot x_j) \right| \cdot 2^{-k} \right); \quad \text{IPR: } x_j \in [-1000, 1000] \quad (27)$$

Here $\text{nint}()$ denotes the function which finds the nearest integer and the constant β is set to 32. The global minimum is $f_{12}(0) = 1$ and the VTR was set to 1.05.

13 Rastrigin's Function

$$f_{13}(x) = D \cdot 10 + \sum_{j=1}^D (x_j^2 - 10 \cdot \cos(2\pi \cdot x_j)); \quad \text{IPR: } x_j \in [-600, 600] \quad (28)$$

The global minimum is $f_{13}(0) = 0$ and the VTR was set to 0.9.

22

Resultados - Funções

14 Griewangk's function

$$f_{14}(x) = \sum_{j=1}^D \frac{x_j^2}{4000} - \prod_{j=1}^D \cos\left(\frac{x_j}{\sqrt{j}}\right) + 1; \text{ IPR: } x_j \in [-600, 600] \quad (29)$$

Eq. (29) is a generalization of (12) with the same global minimum $f_{14}(0) = 0$. The VTR here was defined to be $1.e^{-3}$.

15 Ackley's function

$$f_{15}(x) = -20 \cdot \exp\left(-0.02 \cdot \sqrt{D^{-1} \cdot \sum_{j=1}^D x_j^2}\right) - \exp\left(D^{-1} \cdot \sum_{j=1}^D \cos(2\pi \cdot x_j)\right) + 20 + \exp(1);$$

IPR: $x_j \in [-30, 30]$ (30)

The global minimum is $f_{15}(0) = 0$ and the VTR is set to $1.e^{-3}$.

23

Resultado – Storn & Price 1997

Table 2. Averaged number of function evaluations (nfe) required to find the global minimum. NA stands for “not available”.

$f_i(x)$	D	nfe			DE-Settings		
		BGA	EASY	DE/rand/1/bin	NP	F	CR
11	30	NA	27,111	16,907	20	0.5	0.1
11	100	NA	104,520	56,145	20	0.5	0.1
12	10	NA	9,626	4,269	15	0.5	0.1
12	30	NA	39,333	12,859	15	0.5	0.1
13	20	3,608	6,098	12,971	25	0.5	0
13	100	25,040	45,118	73,620	25	0.5	0
14	20	66,000	26,700	8,691	20	0.5	0.1
14	100	361,722	77,250	31,796	20	0.5	0.1
15	30	19,420	13,997	12,481	20	0.5	0.1
15	100	53,860	57,628	36,801	20	0.5	0.1

BGA – Breeder Genetic Algorithm – Muehlenbein (1993) (representacao real)
EASY – Evolutionary Algorithm with Soft Genetic Operators – Voigt (1992)

24

Bilal, M. Pant, H. Zaheer et al.

Differential Evolution: A review of more than two decades of research
Engineering Applications of Artificial Intelligence 90 (2020) 103479

Table 1

DE and its variants with citations above 500.

Variants	Year	Number of citation
Basic Differential Evolution (DE) (Storn and Price, 1997)	1996	20 366
Self-Adaptive Differential Evolution (SaDE) (Qin and Suganthan, 2005)	2005	2410
Adaptive Differential Evolution with Optional External Archive (JADE) (Zhang and Sanderson, 2009)	2009	1888
Opposition Based Differential Evolution (ODE) (Rahnamayan et al., 2008)	2008	1296
Neighborhood Based Differential Evolution (NDE) (Das et al., 2009)	2009	960
Composite Differential Evolution (CoDE) (Wang et al., 2011)	2011	898
Fuzzy Adaptive Differential Evolution (FADE) (Liu and Lampinen, 2005)	2005	857
Generalized Differential Evolution (GDE3) (Kukkonen and Lampinen, 2005)	2005	523

<https://doi.org/10.1016/j.engappai.2020.103479>

25

Bilal, M. Pant, H. Zaheer et al.

Differential Evolution: A review of more than two decades of research
Engineering Applications of Artificial Intelligence 90 (2020) 103479

Table 2

Performance of DE variants in different CEC competition.

DE variant	CEC competition	Rank
SaDE (Qin and Suganthan, 2005)	CEC 2005	3rd
ϵ _DE (Takahama and Sakai, 2006)	CEC 2006	1st
GDE3 (Kukkonen and Lampinen, 2005)	CEC 2007	2nd
jDEdynNP-F (Brest et al., 2008)	CEC 2008	3rd
jDE (Brest et al., 2006)	CEC 2009	1st
ϵ DEg (Takahama and Sakai, 2010)	CEC 2010	1st
DE-ACr (Reynoso-Meza et al., 2011)	CEC 2011	2nd
SHADE (Tanabe and Fukunaga, 2013)	CEC 2013	4th
L-SHADE (Tanabe and Fukunaga, 2014)	CEC 2014	1st
SPS-L-SHADE-EIG (Guo et al., 2015)	CEC 2015	1st
L-SHADE-Epsin (Awad et al., 2016a)	CEC 2016	1st
L-SHADE-cnEpsin (Awad et al., 2017a)	CEC 2017	3rd
L-SHADE-RSP (Akhmedova et al., 2018)	CEC 2018	2nd

<https://doi.org/10.1016/j.engappai.2020.103479>

26

Evolução do DE

- **jDE** – Basea-se na mutacao DE/rand/1/bin (jDE-2 adotou 2 estratégias de mutação) : Controle de parametros F_i e CR_i geração com distribuição normal.

Brest et al IEEE TRANSACTIONS ON EVOLUTIONARY COMPUTATION, VOL. 10, NO. 6, DECEMBER 2006

- **SaDE** – Implementa simultaneamente DE/rand/1 e DE/current-to-best/1 : Adota um ou outro depois de 50 geracoes baseado nas taxas de sucesso de cada uma das 2 variantes do DE. Mais tarde adota tambem busca local quando atinge 200 geracoes.

A. K. Qin and P. N. Suganthan, "Self-adaptive differential evolution algorithm for numerical optimization," in *Proc. IEEE Congr. Evol. Comput.*, vol. 2. Sep. 2005, pp. 1785–1791

28

Evolução do DE (Cont)

- **ODE** – Opposition-based DE ([Opposition-based learning: a new scheme for machine intelligence](#) - Tizhoosh na conference on computational intelligence for modelling, 2005)

Definicao: $\text{Opp}(x) = a+b-x \quad \forall x \in [a,b]$

Opposition-based Inicialization – Inicia Pop aleatoriamente, acha opposition dos N indiv. e escolhe N melhores indivíduos.

Opposition-based Generation – Vai guardando num arquivo a pop da geração G , x_i , e os vetores tentativas, ui , assim como $\text{Opp}(ui)$, escolhendo no final do loop geracional os N melhores indivíduos para próxima geração, $G+1$.

Opposition-based best individual jumping – using the probability J_r para efetuar o jumping, calcula-se o opp do ponto usando os limites de max e min da população e não os limites laterais do espaço de busca. Substitui-se o individuo para fugir de ótimos locais.

S Rahnamayan, HR Tizhoosh, MMA Salama [A novel population initialization method for accelerating evolutionary algorithms](#) Computers & Mathematics with Applications, 2007

S. Rahnamayan, H. R. Tizhoosh, and M. M. A. Salama, *Opposition-based differential evolution*, *IEEE Trans. Evol. Comput.*, vol. 12, no.1, pp. 64–79, Feb. 2008

29

Evolução do DE (Cont.)

- **JADE** Basea-se no DE/current-to-pbest/1/bin

Mutation:

$$v_{i,G+1} = x_{i,G} + F(x_{pbest,G} - x_{i,G}) + F(x_{r1,G} - \tilde{x}_{r2,G})$$

$\tilde{x}$ é escolhido dentre a pop atual **N** (JADE/wo) ou entre **N+Arquivo** (JADE/with)

Optimal external archive (A): JADE/with e JADE/wo

Updating control parameter: CR_i e F_i escolha randômica com distribuição normal para CR_i , e dist Cauchy para F_i . Com isso cria dois outros parametros, c e p , mais fáceis de ajustar, com limites mais estreitos. Para isso usa arquivos de sucesso para F_i e CR_i , Scr e Sf .

Zang & Sanderson. **JADE: Adaptive Differential Evolution With Optional External Archive**, IEEE TRANSACTIONS ON EVOLUTIONARY COMPUTATION, VOL. 13, NO. 5, OCTOBER 2009

30

Evolução do DE (Cont.)

- **SHADE:** Versão do JADE onde se introduz o histórico de sucessos em memória de tamanho fixo pre-definido H , memórias denominadas Mf e Mcr . As medias ponderadas do JADE serão a partir deste arquivo de memória de sucesso e a media da distribuicao normal e de Cauchy serão sorteadas dentro do arquivo de memória. p do pbest, aqui, é aleatório escolhido no interval $\text{rand} \{2/N; 0,2\}$

R. Tanabe and A. Fukunaga, "Success-History Based Parameter Adaptation for Differential Evolution," in IEEE CEC, 2013, pp. 71–78

- **L-SHADE:** parte do SHADE, adotando uma redução linear simples do tamanho N da população, excluindo-se os individuos de pior avaliação. (NFE – number of function evaluations e $N^{min} = 4$)

$$N_{G+1} = \text{round} \left[\frac{N^{min} - N^{ini}}{NFE_{max} - NFE_{atual}} NFE_{atual} + N^{ini} \right]$$

R. Tanabe and A. Fukunaga, "Improving the search performance of SHADE using linear population size reduction", in 2014 IEEE Congress on Evolutionary Computation (CEC2014). IEEE, 2014, pp. 1658-1665.

31

Evolução do DE (Cont.)

- **DE/EIG** – Eigenvector-based Crossover Operation

Foi inspirado na eficiencia inquestionável do CMAES, assim como no trabalho do DCMA-ES dado abaixo que guiou sua implementação no DE.

A modificação foi testada em duas mutacoes do DE e denominadas:

DE/best/1/EIG

DE/rand/1/EIG

Trata-se de manter o crossover “binario” aplicando-se antes uma rotação do sistema de coordenadas das variáveis na direção da máxima variância, definido pelos autovetores da matriz de covariância.

Guo & Yang Enhancing Differential Evolution IEEE TRANSACTIONS ON EVOLUTIONARY COMPUTATION, VOL. 19, NO. 1, FEBRUARY 2015

Inspiração: DCMA-ES S. Ghosh, S. Das, S. Roy, S. K. Minhazul, and P. N. Suganthan, “A differential covariance matrix adaptation evolutionary algorithm for real parameter optimization,” *Inf. Sci.*, vol. 182, no. 1, pp. 199–219, Jan. 2012.

32

Evolução do DE (Cont.)

- **SPS-L-SHADE-EIG** – Operador de cruzamento EIG + SPS
Successful Parent Selection - Ganhador do CEC 2015

SPS – procedimento de controle da estagnacao: depois de Q tentativas sem sucesso, seleciona-se de um arquivo de memória um pai anterior que obteve sucesso mas foi, em um momento descartado. Cria portanto outro parametron, Q.

S.M. Guo, J.H. Tsai, C.C. Yang, P.H. Hsu, "A self-optimization approach for l-shade incorporated with eigenvector-based crossover and successful-parent-selecting framework on cec 2015 benchmark set", 2015 IEEE Congress on Evolutionary Computation (CEC), pp. 1003-1010, May 2015

Adicionou duas ideias ao L-SHADE, dos 2 artigos dos mesmos autores, abaixo:

S.M. Guo and C.C. Yang, “Enhancing differential evolution utilizing eigenvector-based crossover operator,” *IEEE Trans. Evol. Comput.*, vol. 19, no. 1, pp. 31–49, Feb. 2015.

S.M. Guo, C.C. Yang, P.H. Hsu, and J. S.-H. Tsai, “Improving differential evolution with successful-parent-selecting framework,” *IEEE Trans. Evol. Comput.*, in press, DOI: 10.1109/TEVC.2014.2375933.

33

Evolução do DE (cont.)

- **L-SHADE-EpSin** : Introduces two sinusoidal-based adaptation strategies for scaling factor parameter (to be used just within the first half of the search, leaving classical L-SHADE-based adaptation during the second half) and a local search procedure within L-SHADE.
- **L-SHADE-EpSin-NLS** : Simply is the L-SHADE-EpSin with no local Search (NLS), that showed bias.
- **L-SHADE-cnEpSin** : Differs from L-SHADE-EpSin by making some control parameters of sinusoidal function adaptive, skipping local search procedure and adding eigenvector-based crossover operator.
- **L-SHADE-SPACMA** : The algorithm hybridizes L-SHADE enhanced with modified control parameter adaptation mechanism with CMA-ES. The adaptation mechanism of L-SHADE is divided into two different procedures, one of them is executed during the first, the other during the second part of the search.
- **NSM-L-SHADE-SPACMA** : The Natural Survival Method is applied to the selection of the L-SHADE-SPACMA algorithm to enhance the efficiency.

Piotrowski and Napiórkowski *Step-by-step improvement of JADE and SHADE-based algorithms: Success or failure?* Swarm and Evolutionary Computation Volume 43, December 2018, Pages 88-108 <https://doi.org/10.1016/j.swevo.2018.03.007>

34

Recent Surveys

- <https://www.sciencedirect.com/science/article/abs/pii/S095219762030004X> (2020)
- <https://www.sciencedirect.com/science/article/pii/S2210650217304224> (2019)
- <https://www.sciencedirect.com/science/article/pii/S2210650217305837> (2018)
- <https://www.sciencedirect.com/science/article/pii/S2210650217306600> (2018)
- <https://www.sciencedirect.com/science/article/pii/S2210650216300268> (2017)- population size)
- <https://www.sciencedirect.com/science/article/pii/S2210650216000146> (2016)
- <http://i2pc.es/coss/Docencia/SignalProcessingReviews/Das2011.pdf> (2011)

36

Leiam publicações científicas sobre as variações do DE e as aplicações na sua área de interesse!

https://en.wikipedia.org/wiki/Differential_evolution#/media/File:Ackley.gif

Palavras chave para ler revisões **recentes**:
“survey” ou “review”, “differential evolution”

Obrigada