



CPC881

Mét. Comp. Insp. na Natureza

Colônia de Formigas

Beatriz Lima, Solange Guimarães, Rogério Espíndola

Tópicos

- Introdução e conceitos básicos
- Algoritmo tradicional: SACO
- Outros algoritmos de formigas para otimização combinatória
- ACO para domínios contínuos




Visão geral

As formigas, assim como as abelhas, são insetos que possuem os mais altos graus de organização social, apresentando diversos comportamentos coletivos interessantes. Em especial, pode ser citado o percurso de uma trajetória (mais curta, em geral) da colônia a uma fonte de alimento.

Esta característica fez com que os estudos iniciais de algoritmos inspirados em formigas fossem aplicados a problemas de percursos em grafos. Outros comportamentos das formigas, tal como o da organização de alimentos e de indivíduos dentro do formigueiro, inspirou a aplicação de algoritmos em tarefas de agrupamento, por exemplo.

Com a evolução das pesquisas, os algoritmos transcenderam aos problemas da otimização combinatória (roteamento, alocação, distribuição, dentre outros), sendo aplicados a problemas de otimização numérica e de regressão também.



Visão geral


O comportamento que cada formiga desempenha na colônia pode ser discriminado segundo o papel - rainha, operária (obreira e soldado), alada (macho) - e a fase de desenvolvimento - ovo, larva, pupa, adulta.

A auto-organização da colônia é obtida pelo mecanismo de comunicação utilizando o toque, sons e os feromônios. Estes servem para marcar o caminho até o alimento, indicar a presença de intrusos ou de machos para reprodução, dentre outras sinalizações.

Como feromônios evaporam, em atividades que exigem deslocamento é necessário que haja um reforço de depósito destas substâncias para que o caminho não seja perdido.

Assim, quanto mais formigas seguirem por um dado caminho, mais ocorre o reforço de feromônios nele e maior a atração de outras formigas para segui-lo (alimentação positiva). Quanto menos formigas o seguirem, menor o depósito de feromônios e maior a tendência de seu abandono (alimentação negativa).

Por isso há a tendência de se optar pelos caminhos mais curtos pois estes têm probabilidade de evaporação de feromônios menor do que as dos caminhos mais longos.




Visão geral

A evaporação de feromônios e o efeito na escolha de trajeto

É preciso definir um processo estocástico que possa representar o fenômeno.

Ele é mais crítico para formigas artificiais do que para as naturais.



Visão geral


A auto-organização de uma colônia de formigas promove a realização coletiva das seguintes tarefas:

- regulação da temperatura do ninho;
- formação de pontes vivas;
- exploração de áreas para alimentação;
- construção e proteção do formigueiro;
- organização de indivíduos e itens alimentares;
- cooperação no transporte de itens grandes;
- emigração de uma colônia;
- encontrar os caminhos mais favoráveis do formigueiro à fonte de alimento;
- exploração preferencial da fonte de alimento mais rica disponível;
- reprodução e dieta.

LA RECONSTRUCTION DU NID
ET LES COORDINATIONS INTERINDIVIDUELLES
CHEZ *BELLICOSITERMES NATALENSIS*
ET *CUBITERMES SP.*
LA THÉORIE DE LA STIGMERGIE :
ESSAI D'INTERPRÉTATION
DU COMPORTEMENT DES TERMITES CONSTRUCTEURS.
par Pierre-P. GRASSÉ
INSECTES SOCIAUX, TOME VI, N° 1, 1959.



Available online at www.sciencedirect.com



Cognitive Systems Research xxx (2007) xxx-xxx

Cognitive Systems
RESEARCH

www.elsevier.com/locate/cogsys

Stigmergic epistemology, stigmergic cognition

Action editor: Ron Sun

Leslie Marsh ^{a,*}, Christian Onof ^{b,c}

^a Centre for Research in Cognitive Science, University of Sussex, United Kingdom

^b Faculty of Engineering, Imperial College London, United Kingdom

^c School of Philosophy, Birkbeck College London, United Kingdom

Received 13 May 2007; accepted 30 June 2007

Visão geral

The Self-Organizing Exploratory Pattern of the Argentine Ant

J.-L. Deneubourg,¹ S. Aron,¹ S. Goss,¹ and J. M. Pasteels¹

Accepted 25 January 1989; revised 9 March 1989

Workers of the Argentine ant, Iridomyrmex humilis, start to explore a chemically unmarked territory randomly. As the explorers are recruited and a trail extends from them, new trails are generally constructed between existing trails. The trails have no fixed destination, and strongly resemble the trails of army ants. A minimal model shows how the complex collective structures are generated by the individual workers' simple trail following rules illustrating how complex collective structures can emerge on self-organization.

KEY WORDS: *Iridomyrmex humilis*; Argentine ant; exploratory pattern; mathematical model.

Naturwissenschaften 76, 579–581 (1989) © Springer-Verlag 1989

Self-organized Shortcuts in the Argentine Ant

S. Goss, S. Aron, J. L. Deneubourg, and J. M. Pasteels

Unit of Behavioural Ecology, C.P. 231, Université Libre de Bruxelles, B-1050 Bruxelles

It is evident that finding the shortest route is extremely important not only for Roman road builders, thirsty

such that a forager going in either direction (leaving the nest or leaving the food) must choose between one or the other (at choice points 1 and 2, respectively). Each branch is at an angle of 30° to the axis of the central bridge, so that the forager has no preference for one or the other branch due to its disposition. This value of 30° has been chosen to minimize the perturbation to the forager's movement, so that on leaving one or the other branch they continue rather than double back onto

Positive Feedback as a Search Strategy

Marco Dorigo
PM-AI&R Project
Dipartimento di Elettronica
20133 Milano, Italy
dorigo@elet.polimi.it

Vittorio Maniezzo
PM-AI&R Project
Dipartimento di Elettronica
Politecnico di Milano
20133 Milano, Italy
maniezzo@elet.polimi.it

Alberto Colorni
Dipartimento di Elettronica
Politecnico di Milano
20133 Milano, Italy

Technical Report 91-016



Abstract

A combination of distributed computation, positive feedback and constructive greedy heuristic is proposed as a new approach to stochastic optimization and problem solving. Positive feedback accounts for rapid discovery of very good solutions, distributed computation avoids premature convergence, and greedy heuristic helps the procedure to find acceptable solutions in the early stages of the search process. An application of the proposed methodology to the classical travelling salesman problem shows that the system can rapidly provide very good, if not optimal, solutions. We report on many simulation results and discuss the working of the algorithm. Some hints about how this approach can be applied to a variety of optimization problems are also given.

Ant Colony Optimization (Dorigo, 1991)

ACO é uma metaheurística em que uma coleção de agentes cooperam na produção de boas soluções para problemas de otimização combinatória. Inspirado no forrageamento das formigas, utiliza a metáfora da comunicação via feromônio (depósito, rastreo e evaporação) como o principal elemento para exploração do espaço de busca representado por um grafo.

A sua forma mais simples é conhecida como SACO, Simple ACO, que possui duas etapas: a progressiva, quando as formigas saem da origem/formigueiro e direcionam-se ao destino/alimento, e a regressiva, quando elas retornam à origem após terem atingido o destino.





Ant Colony Optimization (Dorigo, 1991)

As formigas iniciam suas atividades em modo progressivo utilizando critérios estocásticos para avançar dos nós em que estão para seus vizinhos no grafo.

A probabilidade de escolha de cada aresta é definida a partir dos feromônios depositados previamente nas arestas.

Na etapa regressiva, as formigas retornam à origem deterministicamente pelos mesmos caminhos que geraram, depositando uma quantidade de feromônios relacionada à qualidade da solução que encontraram.



Ant Colony Optimization (Dorigo, 1991)

Seja τ_{ij} a qualidade de uma aresta que conecta os nós i e j para o encontro do caminho mais curto, isto é, a quantidade de feromônios ali depositada. Inicialmente, todas as arestas têm o mesmo valor.

A probabilidade de escolha de um nó j por uma formiga estando no nó i pode ser estimada por:

$$p_{ij} = \begin{cases} 0, & j \notin V_i \\ \frac{\tau_{ij}^\alpha}{\sum_{k \in V_i} \tau_{ik}^\alpha}, & j \in V_i \end{cases}$$

em que α é um parâmetro de controle da intensidade do feromônio e V_i é a vizinhança de i .

O nó predecessor a i não faz parte de V_i para evitar o retorno ao estágio imediatamente anterior. Caso ciclos tenham sido produzidos na etapa progressiva, estes devem ser eliminados antes do retorno à origem.



Ant Colony Optimization (Dorigo, 1991)

Após a eliminação de ciclos, a evaporação de feromônios é implementada como uma estratégia para diminuir o risco de convergência prematura, favorecendo a exploração de caminhos alternativos a bons caminhos encontrados. Ela pode ser determinada por:

$$\tau_{ij}(t + 1) = (1 - \rho) \cdot \tau_{ij}(t), \quad \rho \in (0, 1]$$

Após a evaporação, a quantidade de feromônios Δ_{ij} depositada por uma formiga pode ser dada por um valor constante, caso mais simples, ou por uma regra que valorize caminhos mais interessantes (quanto menor o custo do caminho, maior o depósito):

$$\Delta\tau_{ij} = \frac{C}{custo_k},$$

em que C é uma constante e $custo_k$ é o custo do caminho da formiga k .

Ant Colony Optimization (Dorigo, 1991)

Iniciar feromônios

Enquanto critério de parada não for alcançado

 Lançar formigas

 Para cada formiga na fase progressiva em uma quantidade de iterações

 Estimar as probabilidades de transição

 Mover-se para o próximo estado

 Se solução encontrada

 Eliminar ciclos

 Avaliar a solução

 Guardá-la se for a melhor até então

 Evaporar feromônios

 Depositar feromônios

} fase regressiva

Ant System (Dorigo, 1991)

Os feromônios são iniciados com um valor constante:

$$\tau_0 = \tau_{ij}(0) = \frac{m}{L} \quad \forall i, j$$

em que m é a quantidade de formigas e L é o comprimento de um caminho qualquer de uma solução do problema obtida por uma estratégia gulosa, por exemplo.

A probabilidade de escolha de uma aresta por uma dada formiga é estimada por:

$$p_{ij} = \frac{\tau_{ij}^{\alpha} \cdot \eta_{ij}^{\beta}}{\sum_{k \in V_i} \tau_{ik}^{\alpha} \cdot \eta_{ik}^{\beta}}, \quad j, k \in V_i$$

em que η_{ij} é o inverso do custo da aresta (i, j) : $1/\text{custo}_{ij}$. α e β são parâmetros de controle da influência do feromônio e do custo, respectivamente.

Ant System (Dorigo, 1991)

Após todas as formigas terem finalizados suas etapas progressivas, a atualização dos feromônios pode ser resumida em:

$$\tau_{ij}(t+1) = \overbrace{(1-\rho) \cdot \tau_{ij}(t)}^{\text{evaporação}} + \underbrace{\sum_{k=1}^m \Delta\tau_{ij,k}}_{\text{depósito}}$$

O termo de depósito é o acúmulo de parcelas de todas as formigas que passaram pela aresta (i, j) :

$$\Delta\tau_{ij,k} = \begin{cases} C / \text{custo}_k, & (i, j) \in \text{solucao}_k \\ 0, & \text{caso contrario} \end{cases}$$

C é uma constante e custo_k é o custo de solucao_k

Elitist Ant System (Dorigo, 1992)

As arestas que fazem parte da melhor solução já obtida recebem um depósito extra:

$$\tau_{ij}(t+1) = \overbrace{(1-\rho) \cdot \tau_{ij}(t)}^{\text{evaporação}} + \underbrace{\sum_{k=1}^m \Delta\tau_{ij,k}}_{\text{depósito}} + \underbrace{e \cdot \Delta\tau_{ij,best}}_{\text{depósito extra}}$$

$$\Delta\tau_{ij,best} = \begin{cases} 1/\text{custo}_{best}, & (i,j) \in \text{solucao}_{best} \\ 0, & \text{caso contrario} \end{cases}$$

e é o peso do depósito extra da solucao_{best}

Max-Min Ant System (Stützle & Hoos, 1997)

No MMAS, as arestas percorridas recebem depósitos de feromônios com base na melhor solução:

$$\tau_{ij}(t+1) = \overset{\text{evaporação}}{\tau_{min} \left[(1 - \rho) \cdot \tau_{ij}(t) \right]} + \underset{\text{depósito}}{\Delta \tau_{ij,best}}$$

$\tau_{ij} \in [\tau_{min}, \tau_{max}]$, $\tau_0 = \tau_{max}$, τ_{min} e τ_{max} são atualizados sempre que uma melhor solução é encontrada:

$$\tau_{max} = \frac{1}{\rho \cdot custo_{best}}, \quad \tau_{min} = \frac{\tau_{max}}{a}, \quad a \in \mathbb{R}$$

A informação *best* pode ser a da melhor solução da iteração atual ou a da melhor já obtida. Essas opções podem ser adotadas alternadamente, inclusive.

Quando ocorre estagnação durante uma certa quantidade de ciclos, os feromônios são reiniciados.

Ant Colony System (Dorigo & Gambardella, 1997)

A escolha de uma aresta por uma formiga ocorre de acordo com uma regra pseudoaleatória:

- Há uma probabilidade p para a escolha da melhor aresta disponível na vizinhança:

$$j = \underset{l \in V_i}{\operatorname{argmax}} (\tau_{il} \cdot \eta_{il}^{\beta})$$

- Caso o sorteio aleatório não seja favorável à escolha acima, utiliza-se a seleção do AS.

Outra grande diferença está na atualização dos feromônios. Esta etapa é dividida em duas, sendo uma durante a fase regressiva (atualização global) e outra durante a fase progressiva (atualização local).

- Atualização global: ao final de cada ciclo, apenas as arestas da melhor solução disponível são atualizadas:

$$\tau_{ij}(t + 1) = (1 - \rho) \cdot \tau_{ij}(t) + \rho \cdot \Delta\tau_{ij,best} \quad \forall (i, j) \in solucao_{best}$$

Ant Colony System (Dorigo & Gambardella, 1997)

- Atualização local: logo após a formiga passar por uma aresta, é feita uma atualização do feromônio:

$$\tau_{ij}(t + 1) = (1 - \xi) \cdot \tau_{ij}(t) + \xi \cdot \tau_0 \quad \forall (i, j) \in solucao_{best}, 0 < \xi < 1$$

O efeito da atualização local é reduzir a ocorrência de estagnação ao diminuir a quantidade de feromônios da aresta, tornando menor a sua probabilidade de escolha e favorecendo a exploração de outras arestas ainda não percorridas.

Assim como no MMAS, o ACS também impõe limites aos τ_{ij} , dessa vez implicitamente. Pode ser verificado que $\tau_0 < \tau_{ij} < 1/custo_{best}$.

Em problemas com muitas arestas para cada nó, há implementações que utilizam uma heurística de pré-seleção das arestas que serão consideradas para o processo seletivo principal.

ACO_ℝ (Socha & Dorigo, 2006)

Em otimização numérica, a grande mudança de ACO para ACO_ℝ está na função de probabilidade de seleção do próximo passo, que deixa de ser uma distribuição discreta para ser uma função densidade de probabilidade. Assim, uma formiga faz uma amostragem no espaço em vez de escolher uma das transições possíveis em sua vizinhança.



Available online at www.sciencedirect.com



European Journal of Operational Research 185 (2008) 1155–1173

EUROPEAN
JOURNAL
OF OPERATIONAL
RESEARCH

www.elsevier.com/locate/ejor



Ant colony optimization for continuous domains

Krzysztof Socha *, Marco Dorigo

IRIDIA, Université Libre de Bruxelles, CP 194/6, Ave. Franklin D. Roosevelt 50, 1050 Brussels, Belgium¹

Received 1 August 2005; accepted 1 June 2006

Available online 3 November 2006




ACO_ℝ (Socha & Dorigo, 2006)

Fazer a amostragem nem sempre é simples quanto o é para uma distribuição normal. E, mesmo utilizando uma PDF normal, nem sempre a necessidade da modelagem é atendida (exemplo: duas regiões de interesse disjuntas).

Uma abordagem possível é utilizar núcleos gaussianos como as PDFs de cada variável, que podem ser definidos como a soma ponderada das gaussianas individuais de cada região de interesse:

$$G_i(x) = \sum_{l=1}^k w_l \cdot g_{il}(x), \quad g_{il}(x) = \frac{1}{\sigma_{il}\sqrt{2\pi}} \exp\left(-\frac{(x - \mu_{il})^2}{2\sigma_{il}^2}\right)$$

em que k é a quantidade de regiões de interesse, w_l é o peso da região l , $g_{il}(x)$ é a gaussiana da região l da variável i , e μ_{il} e σ_{il} são suas média e desvio-padrão, respectivamente.



ACO_ℝ (Socha & Dorigo, 2006)

O ACO_ℝ mantém uma coleção de k soluções para a produção das PDFs (núcleos gaussianos) das dimensões do problema, que serão usadas para a geração das novas soluções inspirando-se em um ACO baseado em populações.

Cada uma dessas soluções tem um peso de acordo com a sua qualidade, observando a função objetivo, e são ordenadas na tabela de modo decrescente.

Para cada dimensão i do espaço de busca, os pesos w_l são utilizados para ponderar as gaussianas $g_{il}(x)$ na produção dos núcleos gaussianos $G_i(x)$.

s_1	s_1^1	s_1^2	• • •	s_1^i	• • •	s_1^n	$f(s_1)$	ω_1
s_2	s_2^1	s_2^2	• • •	s_2^i	• • •	s_2^n	$f(s_2)$	ω_2
	•	•	•	•	•	•	•	•
	•	•	•	•	•	•	•	•
	•	•	•	•	•	•	•	•
s_l	s_l^1	s_l^2	• • •	s_l^i	• • •	s_l^n	$f(s_l)$	ω_l
	•	•	•	•	•	•	•	•
	•	•	•	•	•	•	•	•
	•	•	•	•	•	•	•	•
s_k	s_k^1	s_k^2	• • •	s_k^i	• • •	s_k^n	$f(s_k)$	ω_k
	•	•	•	•	•	•	•	•
	•	•	•	•	•	•	•	•
	•	•	•	•	•	•	•	•

G^1
 G^2
 G^i
 G^n

ACO_R (Socha & Dorigo, 2006)

Portanto, há a necessidade de se determinar os parâmetros μ_{il} e σ_{il} das gaussianas das regiões de interesse l de cada dimensão i , além do peso w_l :

$$w_l = \frac{1}{q \cdot k \cdot \sqrt{2\pi}} \exp\left(-\frac{(l-1)^2}{2(q \cdot k)^2}\right)$$

em que l é a posição da solução observando a ordenação ($w_1 \geq \dots \geq w_k$) e q é outro parâmetro a ser especificado pelo pesquisador. Quanto menor o valor de q , maior a importância da melhor solução encontrada e maior a probabilidade dela ser selecionada para a geração de novas soluções. Na prática, os pesos são extraídos de uma gaussiana de média 1 e desvio-padrão $q \cdot k$.

Em vez de produzir o núcleo gaussiano para a posterior amostragem, w_l será usado para escolher estocasticamente a região de interesse (logo, sua gaussiana) onde será feita a amostragem:

$$p_l = \frac{w_l}{\sum_{j=1}^k w_j}$$

ACO_ℝ (Socha & Dorigo, 2006)

Para a amostragem em $g_{il}(x)$, sendo l a solução sorteada, μ_{il} é definido como o valor da componente i de l (s_l^i). O desvio padrão σ_{il} é estimado a partir da média das distâncias dos valores das outras soluções ao valor da componente i de l :

$$\sigma_{il} = \xi \cdot \sum_{j=1}^k \frac{|s_j^i - s_l^i|}{k - 1}$$

em que $\xi > 0$ é constante em todas as dimensões e desempenha papel semelhante ao da taxa de evaporação de feromônios no ACO discreto.

Dessa forma, cada formiga constrói sua solução a cada iteração.

Cabe ressaltar que a escolha da solução de referência, para a construção de uma nova, se mantém em todas as dimensões, ou seja, uma vez sorteada a solução l , todas as suas gaussianas $g_{il}(x)$ serão utilizadas para as amostragens dos novos valores.

ACO_R (Socha & Dorigo, 2006)

Para “atualizar feromônios”, a coleção de soluções é atualizada com as m melhores (novas) soluções, que substituem as m piores da coleção atual, $m < k$.

Resumo:

Para cada ciclo

 Para cada formiga/solução

 Sortear uma solução de referência

 Para cada variável/componente da solução

 Obter média e desvio-padrão

 Atualizar valor do componente a partir da sua gaussiana

 fim

 fim

 Atualizar feromônios/população de soluções

fim