

Computação Evolutiva

◆ INTRODUÇÃO

Inspirada na observação e na simulação computacional de processos naturais do mundo real.

- Principal inspiração:

Teoria da evolução natural de Darwin

- Principais Aplicações:

Problemas complexos de síntese e otimização e
aprendizado de máquina

Algoritmos Evolutivos

Métodos de Computação Evolutiva → concebidos para resolverem problemas genéricos.

Operam em mundos não-lineares e não-estacionários:


- Não garantem eficiência total na obtenção da solução
- Garantem a obtenção de uma boa aproximação para a solução

Independente da aplicação, estes métodos baseados em CE devem ser considerados quando os clássicos falham, sendo portanto o último recurso.

O campo de aplicação para técnicas de computação evolutiva é muito vasto, uma vez que o número de problemas tratáveis pelos métodos clássicos é restrito.

Breve comparação

Os **Algoritmos Evolutivos** diferem basicamente dos métodos clássicos de otimização, que usualmente empregam as mesmas abordagens de descida partindo de um ponto inicial arbitrário, por gerar **muitos pontos** espaçados aleatoriamente no espaço de busca.



Novos pontos são gerados aplicando-se **operadores** aos pontos atuais que se movem em direção as regiões ótimas do espaço de busca.

Breve comparação

Trata-se de uma busca inteligente num grande espaço de soluções, porém finito, empregando-se métodos estocásticos.

Os algoritmos evolutivos não requerem derivadas das funções de custo e podem tratar com variáveis discretas e funções descontínuas.

Eles representam processos bem-sucedidos da **natureza** num fenômeno natural de **otimização**.

Teoria da Evolução Natural

"It is not the strongest of the species that survives, nor the most intelligent that survives. It is the one that is the most adaptable to change."

Charles Darwin (1809-1882)

A vida na terra é o resultado de um processo de **seleção**, pelo meio ambiente, dos **mais aptos e adaptados**, e por isto mesmo com mais chances de reproduzir-se.

Evolução - organismos se modificam com o passar do tempo, alguns organismos desapareceram do planeta e são substituídos por outros organismos que não existiam antes.



Histórico e Inspiração Biológica

Data	Autor	Proposta
1801	Lamarck	Evolução através da hereditariedade: características adquiridas durante a vida (Lei do uso e desuso). Mudanças através da vida são transmitidas aos descendentes. (Alg. Meméticos)
1859	Darwin	Princípio fundamental da Seleção Natural como princípio evolutivo.
1865	Mendel	Princípios básicos da transferência de fatores hereditários de pais para filhos. Teoria da hereditariedade e dominância.

A união da genética com diversos conceitos e teorias sobre seleção natural leva ao que hoje é chamado de **neo-Darwinismo** (síntese evolutiva moderna).

Inspiração Biológica

Teoria do neo-Darwinismo:

- Durante a reprodução, traços dos pais são passados aos filhos
- Variações (**mutações**) estão presentes naturalmente em todas as espécies, produzindo novos traços
- Um processo, chamado **seleção natural**, seleciona indivíduos mais adaptados ao ambiente
- Durante longo período de tempo, as variações podem acumular e produzir novas espécies

Inspiração Biológica

Em resumo, a teoria Neo-Darwiniana propõe que a evolução é o resultado de uma (ou mais) população de indivíduos sujeita aos seguintes processos:

- Reprodução com herança
- Variação
- Seleção natural

Inspiração Biológica

- O indivíduo mais adaptado sobrevive por mais tempo
- As características, codificadas nos genes são transmitidas para os filhos e tendem a se propagar nas novas gerações
- Na reprodução sexuada, os cromossomos dos filhos são uma mistura dos cromossomos de seus pais
- As características dos filhos são herdadas parcialmente de seus pais e parcialmente do resultados de novos genes criados durante o processo de reprodução

Analogia com a Natureza - Terminologia

Natureza	Descrição
Cromossomo	Estrutura de dados formada por uma sequência de genes. Codifica uma solução para o problema.
Gene	Componente elementar de um cromossomo, geralmente responsável pela codificação de um único parâmetro, ou seja, um elemento do vetor que representa o cromossomo
Alelo	Representa os valores (dados) que um gene pode assumir
Lócus	Posição ocupada por um gene em um cromossomo
Genótipo	Informação contida no cromossomo. Estrutura de dados que representa uma solução candidata à um determinado problema
Fenótipo	Decodificação de um ou mais cromossomos que leva a um ponto da superfície de adaptação, definida no espaço de busca
Epistasia	Não - linearidade

Analogia com a Natureza - Terminologia

Natureza	Descrição
Indivíduo	Uma solução candidata de um problema
População	Conjunto dos indivíduos de uma geração
Geração	Ciclo de criação e transformação de uma população
Aptidão	Valor associado a um indivíduo que indica o quão bem ele soluciona um determinado problema
Mutação	Variação aleatória em uma estrutura de dados individual
Cruzamento	Troca de porções entre duas ou mais estruturas de dados
Seleção	Processo que permite a sobrevivência e reprodução dos indivíduos mais aptos em detrimento dos menos aptos


Conceitos Básicos da Computação Evolutiva

Simulação computacional do processo de passagem de gerações da evolução natural:

1. Criar uma **população de soluções**, possivelmente na primeira geração de forma aleatória, e na qual os indivíduos tenham registrado de modo intrínseco os parâmetros que descrevem uma possível solução ao problema posto.
2. Empregar um critério - **função de avaliação** - capaz de julgar a aptidão de cada indivíduo. Este critério não precisa deter conhecimento sobre como encontrar uma solução para o problema, mas apenas atribuir uma "nota" ao desempenho de cada um dos indivíduos da população.
3. Empregar uma série de **operadores** que serão aplicados à população de uma dada geração para obter os indivíduos da próxima geração

Conceitos Básicos

Principais operadores :

- **Seleção**: permite escolher **um** indivíduo ou **um par** deles para gerar descendência. 
- **Recombinação (crossover)**: operador que simula a troca de material genético entre os ancestrais que, por sua vez, determina a carga genética dos descendentes
- **Mutação**: operador que realiza mudanças aleatórias no material genético

Filosofia da Teoria da Evolução:

A seleção natural atua de forma a privilegiar organismos cujas **variações** resultam num **maior grau de adaptabilidade** ao ambiente.

Sendo assim, a **evolução** pode ser comparada a um **processo de busca que visa otimizar** a estrutura orgânica dos seres vivos a seus ambientes (através dos processos de **reprodução com herança genética, variação e seleção natural**).


A **evolução** é inerentemente um processo de **otimização**.

Potencialidades dos Algoritmos Evolutivos

- ◆ Método de propósito geral
- ◆ Tratam sistemas complexos com modelos matemáticos difíceis
- ◆ Não requerem informações relativas a derivadas
- ◆ Permitem implementação em paralelo
- ◆ Flexibilidade para hibridizar com outras técnicas

Não existe algoritmo para a resolução de **todos os problemas** de otimização que seja genericamente superior que outro algoritmo competidor.

Algoritmos Evolutivos



Estratégias Evolutivas

Foram inventadas para resolver problemas técnicos de otimização.

Era conhecida somente na comunidade de engenharia como uma alternativa a soluções padrão.

Rechenberg e Schwefel, na década de 60, empregaram:

- parâmetros com **codificação real**
- **mutação** como operador de busca
- população de **um único indivíduo** – mecanismo **(1+1)**
 - Um único indivíduo gera um único descendente por mutação Gaussiana
- Cada indivíduo representado com um par de vetores: $(\mathbf{x}, \sigma)$
 - $\mathbf{x}$ – um ponto do espaço de busca
 - σ - vetor de desvio padrão

Estratégias Evolutivas

Mutações são realizadas substituindo-se $\mathbf{x}_i(t)$ por:

$$\mathbf{x}_i(t+1) = \mathbf{x}_i(t) + N(0, \sigma_i)$$

A cada componente de $\mathbf{x}$, soma-se um número aleatório gerado de uma distribuição Gaussiana com média 0 e desvio padrão σ_i

- ◆ Filhos são produzidos pela mutação dos pais
- ◆ Assim que o filho é gerado, ele é avaliado pela função de avaliação (*fitness*).
- ◆ Se a *fitness* do filho for maior que a do pai, ele o substitui na população, ou então é eliminado
- ◆ O filho compete com o pai e durante este estágio, existem temporariamente 2 indivíduos na população
- ◆ Este procedimento foi chamado de: **EE 2-membros (1+1)**

Estratégias Evolutivas

Rechenberg propôs a “**Regra do 1/5**” para otimizar a taxa de convergência:

“Quando a **taxa de sucesso** após mutação (aptidão do descendente maior que do ascendente) for maior do que 0.2, a variância da distribuição normal deve ser aumentada.

Se ela for menor do que 0.2, a variância deve ser diminuída”.

A objetivo desta regra é aumentar a eficiência da busca:

se sucesso → continuar a busca em passos largos

se não → os passos devem ser menores

Estratégias Evolutivas

- ◆ Essa busca freqüentemente conduzia a convergência prematura, então:
 - aumentou-se o tamanho da população e esta teoria evoluiu para a :

Estratégia multi-membros: EE ($\mu + 1$)

- População de μ indivíduos
- Mantém mutação
- Introduz Recombinação: 2 pais selecionados de maneira aleatória, para gerar um filho
- Este filho substitui (se for o caso) o pior elemento da população
- ◆ Estas estratégias evoluíram para outras estratégias multi-membros:
- Estratégia soma: **EE ($\mu + \lambda$)** e Estratégia vírgula: **EE (μ, λ)**

Estratégias Evolutivas

◆ EE-($\mu + \lambda$):

μ ancestrais geram λ descendentes e competem entre si para a sobrevivência (pais são considerados na seleção).

A população temporária de $(\mu + \lambda)$ indivíduos é reduzida novamente pelo processo de seleção para μ indivíduos.

◆ EE-(μ, λ)

Somente os λ descendentes competem para sobreviver, os pais morrem (somente os descendentes são considerados para seleção).

A vida de cada indivíduo fica limitada a uma geração. Isto permite que esta estratégia tenha desempenho superior em problemas dinâmicos.

Estratégias Evolutivas

A idéia principal dessas 2 estratégias é permitir que variáveis de controle (variância da mutação σ) sejam parâmetros auto-adaptativos:

- ◆ Variáveis de controle não são mais constantes
- ◆ Não trocam seus valores por meio de um algoritmo determinístico, como a Regra do 1/5
- ◆ Variáveis de controle são incorporadas a estrutura dos indivíduos e são parâmetros que evoluem no processo

$$\text{antes: } I: (x) \rightarrow x_i(t+1) = x_i(t) + N(0, \sigma_i)$$

$$\text{final: } I: (x, \underbrace{\sigma, \theta})$$

Variáveis de controle (variâncias e correlações)

Estratégias Evolutivas

Um indivíduo corresponde a um ponto no espaço de soluções, e possui um genótipo formado por: **variáveis objetivo** e **variáveis estratégicas**.

- ◆ **Variáveis objetivo** são aquelas que, sofrendo recombinação e mutação, permitem incrementar a aptidão dos indivíduos em direção ao máximo global de otimização.
- ◆ **As variáveis estratégicas** representam variâncias e correlações, que devem ser operadas junto às variáveis de controle para produzir mutações.


EEs provaram ser eficientes quando comparadas a outros métodos iterativos em um grande número de problemas de teste (Schwefel).

São aplicáveis a inúmeros problemas de otimização, porque necessitam de pouca informação sobre o problema, especialmente as derivadas da função objetivo.

Estratégias Evolutivas – Algumas aplicações

A primeira aplicação de CE em projeto (Schwefel, 1970): **Nozzle**

O genoma descreve uma série de seções cônicas:



Forma Inicial




Forma Final



<http://ls11-www.cs.tu-dortmund.de/people/schwefel/EADemos/>

O problema do caixeiro viajante

O objetivo é achar o caminho mais curto num sistema de n cidades que devem ser visitadas pelo caixeiro viajante. Cada cidade deve ser visitada somente uma vez.




Soluções para 20, 50 e 100 cidades

Tutoriais

Toolbox do Matlab:

<http://www.geatbx.com/docu/algindex.html#TopOfPage>

<http://www.obitko.com/tutorials/genetic-algorithms/index.php>



Algoritmos Genéticos (AG)


- ◆ AGs são indicados em problemas complexos de otimização:
 - muitos parâmetros e variáveis;
 - mal estruturados: com condições e restrições, difíceis de serem modelados matematicamente;
 - grandes espaços de busca;
 - objetivos múltiplos.

Características dos Algoritmos Genéticos (AG)

- ◆ Operam com uma codificação das possíveis soluções (espaço **genotípico**) e não com as próprias soluções (espaço **fenotípico**)
- ◆ o AG's fazem busca sobre uma **população** de pontos e não sobre um único ponto
- ◆ AG's fazem uso de descrições genéricas do que se quer ver presente na solução, através de **funções de fitness** (funções-objetivo)
- ◆ o AG's utilizam regras de transição **probabilísticas**, e não regras determinísticas

Componentes dos Algoritmos Genéticos

- **Representação** – Estrutura de dados
- **Seleção Natural** - Função de avaliação
- **Operadores Genéticos**



Inicie a população

Avalie indivíduos na população

Repita

Selecione indivíduos para reprodução

Aplique operadores de **cruzamento** e **mutação**

Avalie indivíduos na população

Selecione indivíduos para sobreviver

Até **critério de parada** satisfeito

Fim

Espaço de busca

- ◆ É definido pelo conjunto de todas as soluções possíveis
- ◆ O tamanho do espaço de busca pode ser uma medida da complexidade do problema
- ◆ Os operadores genéticos de cruzamento e mutação implementam um passeio pseudo-aleatório através do espaço de busca
 - ◆ Operações genéticas são não-determinísticas
- ◆ Este passeio é direcionado, uma vez que o algoritmo deseja maximizar a qualidade das soluções empregando uma função objetivo


Busca Global e Local

◆ Busca Local

- Procura soluções no espaço de busca próximas à soluções existentes
- *Crossover* é o operador principal no processo da busca local


◆ Busca Global

- Procura soluções em novas áreas do espaço de busca
- Mutação é o operador principal no processo da busca global




Representação – Estrutura de dados


Espaço fenotípico



Codificação



Espaço genotípico



Decodificação



Cromossomos: conj de genes

AG clássico: Cadeias binárias de comprimento fixo (cromossomos)

111011011

Representação – Estrutura de dados

Outras estruturas de dados :

- Vetores de reais: (12.34, 7.35, 3.51, 3.4)
- Vetores de inteiros: (1,7,2,5,2,8)


Um cromossomo representa **um conjunto de parâmetros** da função objetivo cuja resposta será maximizada ou minimizada.

O conjunto de todas as configurações que o cromossomo pode assumir compõe o **espaço de busca**.

Representação – Estrutura de dados

Cada pedaço do cromossomo (gene) tem informação sobre um parâmetro a ser otimizado.

Exemplo:



Indivíduo (cromossomo): 01001010 11100010 00001110

gene (característica)

alelo (valor da característica) = 1.57

Representação – Estrutura de dados

Se o cromossomo representa n variáveis de uma função, então o espaço de busca é um espaço de n dimensões.

Sendo as variáveis $x_1, x_2, \dots, x_n$, o cromossomo pode ser escrito como um vetor da seguinte forma:


cromossomo = $[x_1, x_2, x_3 \dots x_n]$

Representação Binária

- ◆ simples de criar e manipular
- ◆ produz bons resultados
- ◆ facilita aplicações de operadores
- ◆ fácil decodificação numérica (inteiro, real)
- ◆ nem sempre é adequada ou suficiente

Representação Binária

- variáveis: $(X_1, X_2, \dots, X_n)$
- domínio: $X_i \in (\text{mín}_i, \text{máx}_i)$ em $\mathbb{R}$
- precisão: p casas decimais



Representação Binária

$$2^{nb} \geq (\text{máx}_i - \text{mín}_i) \times 10^p$$

$$\varepsilon = \frac{(\text{máx}_i - \text{mín}_i)}{2^{nb} - 1}$$

$$\varepsilon = \text{precisão} = 1/10^p$$

O **número de bits** (nb) necessários para garantir a precisão ε é:


$$nb = \log_2 \frac{\text{máx}_i - \text{mín}_i}{\varepsilon}$$

Cadeias mais longas proporcionam maior precisão numérica à solução

Representação Binária

Exemplo 1: Na função $f(x) = x \cdot \sin(10 \pi x) + 1$

Achar o valor que maximiza f no intervalo $[-1, 2]$



Para uma precisão de 6 casas decimais:

$$(\text{máx}_i - \text{mín}_i) \times 10^p = 3 \times 10^6$$

$$2^{nb} \geq (\text{máx}_i - \text{mín}_i) \times 10^p$$

$$2097152 = 2^{21} < 3000000 \leq 2^{22} = 4194304$$

Necessita-se de 22 bits para codificar o cromossomo

Representação Binária

Ex. Decodificação para Real:

Para uma variável discreta representada por $x_i = \mathbf{0011}$

- Índice (IND) de referência no espaço de busca:

$$\text{IND} = 0 \times 2^3 + 0 \times 2^2 + 1 \times 2^1 + 1 \times 2^0 = 3$$

- A decodificação fornece um valor real da seguinte forma:

$$x = \text{mín}_i + \text{IND} \times \varepsilon$$

$$\varepsilon = \frac{\text{máx}_i - \text{mín}_i}{2^{nb} - 1}$$

População inicial

Cada cromossomo é um vetor binário de n bits, onde todos estes bits são inicializados aleatoriamente.

Cromossomo em um AG clássico: (1000101110110101000111)

Locus

População inicial:

```
1000101110110101000111
0100101010110101000111
1100100010110101000101
0001100110110101000110
1010101010110101000010
1110100010110101011000
```



N indivíduos

Seleção Natural

É o princípio básico para o direcionamento da evolução de uma população

A seleção é responsável por escolher os indivíduos que estão **mais aptos** a se tornarem **genitores** para a próxima geração.

- Utiliza uma função de avaliação para medir a **aptidão** de cada indivíduo

Nota associada ao indivíduo que **avalia** quão boa é a solução por ele representada.

- Essa **aptidão** pode ser **absoluta** ou **relativa**

- Igual a função objetivo
- Resultado do **escalonamento** da função objetivo.
- Baseado no **ranking** do indivíduo da população.

Seleção Natural

Para **Aptidão** igual a função objetivo:

Do exemplo 1: $f(x) = x \cdot \sin(10 \pi x) + 1$

Para 3 cromossomos:

I1 = (10001011110110101000111) $f(x_1) = 1.586345$

I2 = (0000001110000000010000) $f(x_2) = 0.078878$

I3 = (1110000000111111000101) $f(x_3) = 2.250650$

O melhor cromossomo entre os 3
que maximiza a função

Seleção Natural

Função Aptidão

Representa uma medida da capacidade de sobrevivência de um cromossomo no processo de evolução, e consequentemente a probabilidade dele se reproduzir com mais frequência.

É uma composição da função objetivo, com funções de penalidade, estabelecidas a partir das restrições do problema.

Principais Métodos de Seleção


Chances de **seleção são proporcionais à aptidão**.

- Principais **métodos de seleção**:

- Roda da Roleta
- Torneio
- Amostragem Universal Estocástica

População intermediária

Os indivíduos mais aptos têm maior chance de serem selecionados para uma população intermediária de genitores: ***mating pool***.



Seleção por Roleta


Objetivo: Selecionar indivíduos proporcionando aos mais aptos maiores chances de reprodução.

- > atribuir a cada indivíduo uma fatia da roleta
- > girar a roleta n vezes para selecionar n indivíduos

$$\text{aptidão}(A) = 3 \quad 3/6 = 50\%$$

$$\text{aptidão}(B) = 1 \quad 1/6 = 17\%$$

$$\text{aptidão}(C) = 2 \quad 2/6 = 33\%$$



Seleção por Roleta

Método

- Encontre a soma da aptidão de todos os membros da população $A_T = \sum A_i$ ($0 \leq i \leq \text{tamanho da população} - 1$)
- Gere um número aleatório $0 \leq \text{random} \leq A_T$
- Tome o primeiro membro da população I_k cuja aptidão acumulada (aptidão somada às aptidões dos membros precedentes) é maior ou igual ao número aleatório gerado.

$$\sum A_i \geq \text{random} \quad (i < k)$$

Seleção por Roleta

Exemplo:


Indivíduo	Aptidão Absoluta	Aptidão Acumul.
1	5	5
2	2	7
3	4	11
4	18	29
5	9	38
Total	38	

No. Aleatório	Aptidão Ac $\geq$ no.aleatório	Indivíduo Selecionado
8	11	3
18	29	4
3	5	1
30	38	5
21	29	4

Seleção por Torneio


Método:

- n indivíduos são selecionados aleatoriamente na população, e na comparação entre eles, o melhor indivíduo é copiado para a população intermediária.
- O processo é repetido até completar a população intermediária.
(Para selecionar j indivíduos, realiza-se o processo j vezes)
- Geralmente n igual a dois ou três.



Seleção por Amostragem Universal Estocástica

- Semelhante à Roleta,
- Para selecionar m indivíduos utiliza m apontadores igualmente espaçados,
- Gira-se em conjunto uma só vez



Pais selecionados:

2, 4, 5 e 5

Seleção

Após a **seleção**, os indivíduos armazenados na geração intermediária são submetidos ao processo de reprodução, para então formarem uma **nova geração**.

Se uma geração é totalmente substituída por outra mais jovem, pode-se perder um indivíduo de boa qualidade.

Para que isto não ocorra, um percentual da população que tenha um desempenho exemplar pode ser mantida na geração seguinte, copiando-se estes indivíduos diretamente.

Esta prática é denominada **elitismo**.

Operadores Genéticos

Na fase de **reprodução**: indivíduos selecionados são submetidos a um operador genético

Formam novos indivíduos que substituirão a geração anterior: total ou parcialmente

Crossover

Mutação

Crossover: geralmente aplicado a **pares de cromossomos** retirados da população intermediária: formando dois novos cromossomos - "filhos"


Mutação: estes cromossomos são submetidos à troca de material genético (parte da cadeia de bits, no caso de codificação binária).

Operador de Cruzamento: *Crossover*

Nos sistemas biológicos o *crossover* pode ocorrer durante a reprodução sexuada permitindo a **troca de material genético** entre dois indivíduos.

O *crossover* é o operador principal do AG:

- Responsável por gerar novos indivíduos (melhores ou piores) a partir de indivíduos já promissores
- Aplicado a cada par de indivíduos com alta probabilidade (pc):
normalmente: $0,5 < pc < 1,0$
- Pode ser associado um número aleatório aos pares de indivíduos, se este valor for menor que a taxa pc ocorre o cruzamento
- Alguns indivíduos podem ser preservados integralmente




Crossover

Sequência:

- Selecionar aleatoriamente 2 indivíduos do *mating pool*
- Gerar um número aleatório a entre 0 e 1
 - Se $a < pc$ então ocorre cruzamento
- Ponto de corte (ou de cruzamento):
 - gerar um número aleatório inteiro no intervalo 1 a $(l-1)$
(l é o comprimento do cromossomo)
- Trocar as porções dos cromossomos localizados após o ponto de corte


Crossover

- Tipos:
- Simples (1 ponto)
 - Múltiplo
 - Uniforme



Operador de Mutação

Em genética a **mutação** pontual é um processo no qual um alelo de um gene é aleatoriamente substituído (ou modificado) por outro, resultando em um novo cromossomo.




O **operador de mutação** tem o objetivo de **melhorar a diversidade** na população, impedindo problemas de convergência prematura, contudo ele destrói parte da informação contida no cromossomo.

Operador de Mutação

A **diversidade** se refere a uma distância média entre os indivíduos da população.

Uma população tem alta diversidade se a distância média é grande.



A diversidade é essencial para o AG porque ela permite que a busca seja realizada numa região mais ampla do espaço de busca.

Operador de Mutação

Geralmente existe uma **baixa probabilidade** de mudar cada gene de um cromossomo:

Taxa de mutação recomendada: $0,1\% < pm < 5\%$.

Alguns autores sugerem:

$$1 / \text{tam_pop} < pm < 1 / \text{comprim_cromossomo}$$

Operador de Mutação

Para codificação binária - inverte o valor de um bit do cromossomo filho, com uma dada probabilidade.

- A mutação somente ocorre naqueles alelos que tiverem o número aleatório (entre 0 e 1) associado a eles menor que a taxa pm .

Exemplo: $pm = 0,8\%$ (0,008)

Cromossomo				Número Aleatório				Novo Cromossomo			
1	0	1	0	0,890	0,122	0,275	0,312	1	0	1	0
1	1	0	0	0,148	0,969	0,005	0,880	1	1	1	0
0	0	1	0	0,778	0,573	0,881	0,002	0	0	1	1

Mutação

A Mutação é um evento decidido com a pm para cada alelo do cromossomo, para cada indivíduo da população.

Este tipo de implementação torna o operador caro computacionalmente.

Por exemplo:

Para uma população de 100 indivíduos e cromossomo de comprimento 44. Deve-se verificar 4400 bits em cada geração.

Para $pm = 0.01 \rightarrow$ espera-se que ocorram $0.01 \times 4400 = 44$ mutações/geração

Evolução

■ Crossover:

- acelerador do processo de busca
- tira proveito das soluções mais promissoras

■ Mutação

- operador exploratório
- dispersa a população pelo espaço de busca

Evolução

Critérios de parada

- Se o valor ótimo é conhecido: a parada é determinada assim que o algoritmo atingir este valor durante o processo de evolução
- Interromper o algoritmo assim que ele atinja um número pré-determinado de gerações (este é o mais simples deles).
- Parar o processo quando uma ou mais condições forem satisfeitas:
 - não houver melhora no valor da aptidão do melhor indivíduo ou da média das aptidões, para algumas gerações consecutivas
 - a média das aptidões se aproximar da aptidão do melhor indivíduo
 - a variedade genética for menor que um limite mínimo estabelecido


Parâmetros de controle

- Tamanho da população
- Número de gerações/avaliações
- Taxa de *crossover*
- Taxa de mutação
- Aptidão
- Etc.

Exemplo de um problema simples (Goldberg)

Maximizar a função $f(x) = x^2$

x entre $\{0,1,\dots,31\}$



Representação binária: 5 bits

Cromossomo	valores
00000	$\leftrightarrow 0$
11111	$\leftrightarrow 31$

Exemplo (cont.)

Parâmetros:

- População inicial gerada aleatoriamente:
Tamanho da população: 4
- Seleção: roda da roleta
- *Crossover*: de 1 ponto com $pc = 1.0$
- Mutação: bit a bit com $pm = 0.001$


Exemplo (cont.): seleção

No.indiv	cromossomo	x	$f(x)$	$f_i / \sum f$	$f_i / f_{méd}$	No. filhos
1	01101	13	169	0.14	0.58	1
2	11000	24	576	0.49	1.97	2
3	01000	8	64	0.06	0.22	0
4	10011	19	361	0.31	1.23	1
Σ			1170	1.00	4	4
Média			293	0.25	1	1
Maximo			576	0.49	1.97	2

O melhor
teve mais
cópias

O pior
morreu

$f_i / \sum f$ - probabilidade
de seleção



O número esperado de filhos é:

$$f_i / f_{méd}$$

Exemplo (cont.): *crossover*

No.indiv	Pop. Interm.	Pt de corte	Nova população	x	$f(x)$
1	0110 1	4	01100	12	144
2	1100 0	4	11001	25	625
2	11 000	2	11011	27	729
4	10 011	2	10000	16	256
Σ					1754
Média					439
Maximo					729

Exemplo (cont.): *mutação*

No.indiv	Nova população	Mudar bit	Nova pop. após mut.	x	$f(x)$
1	01100	1	11100	26	676
2	11001	-	11001	25	625
3	11011	-	11011	27	729
4	10000	-	10000	16	256
Σ					2286
Média					571.5
Maximo					729

Exemplo (cont.): Resumo

No.indiví duo	População inicial	x	$f(x)$	Pop. após 1 geração	x	$f(x)$
1	01101	13	169	11100	26	676
2	11000	24	576	11001	25	625
3	01000	8	64	11011	27	729
4	10011	19	361	10000	16	256
Σ			1170			2286
Média			293			571.5
Maximo			576			729

O melhor indiv. da pop. Inicial
teve 2 cópias devido a sua aptidão
acima da média

Ao cruzar com o 2º. melhor
indiv. resultou em novo indiv
ainda melhor (11011)

Aumentaram...

Sorte? Não!

Comentários sobre o AG simples

- Já foi muito estudado, mas ainda serve de referência para novas variações implementadas nos AGs
- Apresenta algumas deficiências, tais como:
 - Representação é muito restritiva
 - Mutação e *crossover* são aplicáveis somente a representações binárias e de números inteiros
 - Mecanismo de seleção é sensível a populações com aptidões muito próximas

Comentários sobre o AG simples

Vantagens:

- Técnica de busca global
- Otimização de problemas mal estruturados
- Dispensa formulação matemática precisa do problema

Desvantagens:

- Dificuldade na representação do cromossomo
- Evolução demorada em alguns problemas
- Modelagem depende de especialista em AG

Diferenças básicas entre AG e EE

AG	EE
Formulado como técnica de busca	Desenvolvido como método de otimização numérica
Representação original: Binário	Representação original: Real
Seleção probabilística e preservativa	Seleção determinística e extintiva
Auto-adaptação: permitida em algumas abordagens. No AG clássico os parâmetros de reprodução são constantes	Auto-adaptação: parâmetros de reprodução mudam todo o tempo. Emprega desvio-padrão e covariância
Cruzamento é o operador principal	Mutação é o operador principal

A diferença entre estas duas abordagens tem diminuído ao longo do tempo.