

EVOLUTIONARY ALGORITHMS

Human related:
harmony search (HS),
teaching learning-based
optimization (TLBO)...

Physics-based:
gravitational search
algorithm (GSA), colliding
bodies optimization
(CBO), black hole (BH) ...



Non-biological: differential
evolution (DE), evolution
strategy (ES), evolutionary
programming (EP), sine cosine
algorithm (SCA)...

ETC...

Bio-inspired: genetic algorithm (GA),
immune system algorithm (ISA,
Clonalg), genetic programming (GP),
Biogeography-Based Opt algorithm (BBO), ...

Swarm intelligence: ant colony
optimization (ACO), particle swarm
optimization (PSO), artificial bee
colony (ABC), social spider algorithm
(SSA), social spider optimization
(SSO), bacterial foraging optimization
(BFO)...

EA Publications



Number of publications of evolutionary algorithms and nature-inspired algorithms for real-parameter optimization (2017).

“Since CEC 2005 competition on real-parameter optimisation: a decade of research, progress and comparative analysis’s weakness”, García-Martínez et al. Soft Comput (2017) 21:5573–5583

“Since CEC 2005 competition on real-parameter optimisation: a decade of research, progress and comparative analysis’s weakness”, García-Martínez et al. Soft Comput (2017) 21:5573–5583

The papers have the tendency of comparing among proposals of the same community The analysis of the graph




Fig. 2 Algorithms comparison social network

Particle Swarm Optimization (PSO) Otimização por Enxame de Partículas

Beatriz de S. Leite Pires de Lima
Grasiele Duarte
Rogério Espindola
Solange Guimarães

Particle Swarm Optimization (PSO) Otimização por Enxame de Partículas

A técnica de otimização baseada em enxame de partículas (*Particle Swarm Optimization*) foi proposta por:

um psicólogo da área social, Kennedy e
pelo engenheiro eletricitista Eberhart, em 1995 .

Inspirada no comportamento social de organismos como bando de pássaros e cardume de peixes.

PSO não é apenas uma ferramenta de otimização, é também capaz de criar uma simulação do comportamento social humano, representando sua capacidade de processar conhecimento, baseada nos princípios da psicologia social.

Coletividade nas sociedades de animais

Parecem ocorrer:

- ◆ Em todos os meios (ar, água, terra)
- ◆ Várias famílias (insetos, pássaros, peixes, mamíferos)
- ◆ Animais de diferentes idades e tamanhos



Fenômenos:

- ◆ Movimentos rápidos de todo o bando
- ◆ Reatividade a predadores
- ◆ Reatividade a obstáculos
- ◆ Membros do bando não colidem
- ◆ Sem um líder



Mecanismos:

- ◆ Balanceamento entre atração e repulsão
- ◆ Coordenação auto-organizada
- ◆ sincronismo

PSO - Inspiração

Vários cientistas simularam interpretações de movimentos de organismos num cardume de peixes e num bando de pássaros.

Reynolds (1987) e Heppner (1990) apresentaram simulações de um bando de pássaros.



Os trabalhos pioneiros com bando de pássaros tinham como objetivo entender as regras que regem uma revoada

Reynolds ficou intrigado com a coreografia dos pássaros.

O zoólogo Heppner estava interessado em descobrir regras que regiam o comportamento do bando.

PSO - Inspiração

Algumas regras que regem o comportamento do bando:

- ◆ Voam em sincronia
- ◆ Trocam sempre de direção repentinamente
- ◆ Se espalham e se reagrupam, etc...

Estes cientistas perceberam que os processos locais, causavam a imprevisível dinâmica de grupo do comportamento social dos pássaros, como os autômatos celulares.

Ambos os modelos dependem da manipulação das distâncias inter-individuais:

a sincronia do comportamento do bando foi concebida como uma função dos esforços dos pássaros em manter uma distância ótima entre eles e seus vizinhos.

PSO - Inspiração

Supõe-se que algumas destas regras se aplicam a outros animais com comportamento social, como, rebanhos, cardumes, e outros grupos, como os seres humanos.

Do socio-biólogo E.Wilson, em relação à cardumes de peixes:

"Membros do cardume melhoram sua atuação a partir de descobertas e da experiência anterior de todos os outros membros do cardume em suas buscas por alimento".

Kennedy e Eberhart consideraram essa hipótese fundamental para o desenvolvimento do algoritmo PSO.

Assim como as outras abordagens de inteligência coletiva, PSO está baseado em uma **população de indivíduos capazes de interagir entre si e com o meio ambiente.**



PSO - Inspiração

Um pássaro achar um pouso é análogo a **achar uma solução num espaço de soluções possíveis.**

A maneira que um pássaro, que achou um pouso, levou seus vizinhos também naquela direção, e posteriormente todos do bando, está alinhada com uma perspectiva sócio-cognitiva da mente (inteligência social).

A teoria de Heppner inspirou Kennedy e Eberhart a criar uma metodologia em que **partículas podem sobrevoar um espaço de busca e pousar na melhor solução.**

Como fazer para que as partículas pousem na melhor solução e não numa solução qualquer?

Particle Swarm Optimization (PSO)

"O conhecimento é otimizado por uma interação social e o pensamento não é privado, mas inter-pessoal".

PSO baseado numa teoria sócio-cognitiva:

- ♦ Cada indivíduo de uma população possui sua própria experiência e é capaz de avaliar a qualidade desta experiência
- ♦ Indivíduos são sociais: possuem conhecimentos sobre como seus vizinhos se comportam (desempenho)

Estes dois tipos de informação correspondem à aprendizagem individual (**cognitiva**) e à transmissão cultural (**social**) respectivamente.

Particle Swarm Optimization (PSO)

Em PSO, assim como nos algoritmos evolutivos, existe uma população de indivíduos.

Ao invés de se empregar operadores genéticos, estes indivíduos "evoluem" através de cooperação e competição entre eles, pelas sucessivas gerações.

Cada indivíduo é chamado de partícula e representa uma solução potencial do problema.

Particle Swarm Optimization (PSO)

Resumo do processo de adaptação cultural:

- ♦ **Avaliação:** indivíduos possuem capacidade de sentir o ambiente de forma a avaliar seu próprio comportamento
- ♦ **Comparação:** os indivíduos comparam-se uns aos outros
- ♦ **Imitação:** importante em organizações sociais humanas e para a aquisição e manutenção das habilidades mentais.

Particle Swarm Optimization (PSO)

O algoritmo deve ser implementado de forma a se conseguir um bom **balanceamento entre busca local e global**:

- ♦ Exploração – procura no ambiente uma boa solução
- ♦ Exploração – tira proveito do sucesso obtido anteriormente

Particle Swarm Optimization (PSO)

Algoritmo de otimização - Procedimento de busca baseado numa população onde:

- ♦ **Indivíduos**, chamados de **partículas**, trocam de posição ao longo do tempo.
- ♦ Partículas **sobrevoam** um espaço de busca multi-dimensional.
- ♦ Durante o vôo, cada partícula ajusta sua posição de acordo com **sua própria experiência** e também com a experiência da **partícula vizinha**.

Assim, a partícula faz uso da melhor posição encontrada por ela mesma e por sua vizinhança.

PSO

O algoritmo:

- ♦ Cada vetor solução é modelado como:
 - ♦ as partículas sobrevoam o espaço de busca (coordenadas)
 - ♦ todas as partículas tem velocidade diferente de 0, nunca param de sobrevoar e estão sempre procurando novas regiões
- ♦ Cada partícula lembra do melhor ponto local (**local best**): melhor ponto que ela já encontrou
- ♦ Cada partícula tem conhecimento do melhor ponto global (**global best**): melhor ponto encontrado pelas outras partículas ou por uma vizinhança

PSO

Cada partícula é composta pelos seguintes vetores:

- ♦ $\mathbf{x}_i$ – posição atual da partícula no espaço de busca
- ♦ $\mathbf{p}_i$ - posição da partícula que levou ao seu melhor desempenho até o momento (memória)
- ♦ $\mathbf{p}_g$ - posição encontrada por todo o enxame até o momento (social)
- ♦ $\mathbf{v}_i$ - velocidade atual da partícula

E pelos valores de aptidão:

- ♦ aptidão de $\mathbf{x}_i$
- ♦ aptidão de $\mathbf{p}_i$
- ♦ aptidão de $\mathbf{p}_g$


PSO

O movimento (vôo) de cada partícula no enxame, em cada iteração, corresponde à soma de três termos:

1. Termo relativo à **inércia da partícula** e que traduz o modo com que a partícula vem se movendo;
2. termo relativo à atração da partícula ao **melhor ponto que ela já encontrou (termo cognitivo)**;
3. termo relativo à atração da partícula ao **melhor ponto que todo grupo** (ou uma parte do grupo) já encontrou (**termo social**).

PSO

A busca é guiada pela **auto-consciência** e por uma **consciência coletiva**:



PSO

◆ A partícula i irá se mover da seguinte forma:

$$\mathbf{x}_i(t+1) = \mathbf{x}_i(t) + \mathbf{v}_i(t+1) \Delta t$$

Considera-se $\Delta t = 1$

◆ A velocidade da partícula será dada por:

$$\mathbf{v}_i(t+1) = \underbrace{\mathbf{v}_i(t)}_{\text{inércia}} + \underbrace{\phi_1 \text{ rnd1 } (\mathbf{p}_i - \mathbf{x}_i(t)) / \Delta t}_{\text{termo cognitivo}} + \underbrace{\phi_2 \text{ rnd2 } (\mathbf{p}_g - \mathbf{x}_i(t)) / \Delta t}_{\text{termo social}}$$

ϕ_1 e ϕ_2 - constantes (valor usual ~ 2)

rnd1 e rnd2 - aleatoriedade introduzida no movimento
(no. aleatório com distr. uniforme $[0,1]$)

PSO

O algoritmo introduz uma variável estocástica, que os autores chamam de *craziness*, de forma a evitar que as partículas tomem direções fixas.

(Introduz portanto uma variação para dar à simulação uma aparência real)

Quando se diz que a partícula está indo na direção da sua melhor posição, ela está na verdade indo para um ponto em torno da sua melhor posição:

$$\mathbf{v}(t+1) = \mathbf{v}(t) + \phi_1 \text{rnd1}(\mathbf{p}_i - \mathbf{x}(t)) + \phi_2 \text{rnd2}(\mathbf{p}_g - \mathbf{x}(t))$$

Vale para as 2 direções

Rnd1,2 são diferentes para cada dimensão do problema

PSO

procedure []

 inicialize aleatoriamente **X** e **v**

$t \leftarrow 1$

while $t < \text{max_it}$

for $i = 1$ to N // para cada partícula

if $f(\mathbf{x}_i) > f(\mathbf{p}_i)$ **then**

$\mathbf{p}_i = \mathbf{x}_i$ //melhor indivíduo

endif

for $j = \text{número de vizinhos}$

if $f(\mathbf{p}_j) > f(\mathbf{p}_g)$ **then**

$\mathbf{p}_g = \mathbf{p}_j$ // melhor vizinho

endif

end

$\mathbf{v}_i(t+1) = \mathbf{v}_i(t) + \phi_1 \text{rnd1}(\mathbf{p}_i - \mathbf{x}_i(t)) + \phi_2 \text{rnd2}(\mathbf{p}_g - \mathbf{x}_i(t))$

$\mathbf{x}_i(t+1) = \mathbf{x}_i(t) + \mathbf{v}_i(t+1)$

end

$t \leftarrow t + 1$

end

end

Compara aptidão de cada partícula com sua melhor posição atual e atualiza **p**

Compara aptidão de cada partícula com a melhor posição do enxame e atualiza **p**

PSO - tipos

Kennedy (1997) avaliou 4 tipos de PSO baseando-se na variação de ϕ_1 e ϕ_2 que afetam a influência da memória individual da partícula e da memória coletiva:

- ♦ Modelo Completo: $\phi_1 = \phi_2 > 0$
- ♦ Modelo Cognitivo: $\phi_1 > 0$ e $\phi_2 = 0$
- ♦ Modelo Social: $\phi_1 = 0$ e $\phi_2 > 0$
- ♦ Modelo Generoso: $\phi_1 = 0$, $\phi_2 > 0$, e $g \neq i$
(não considera a própria partícula)

PSO

Kennedy (1997): Para limitar a velocidade de uma partícula de forma que o sistema não exploda, são impostos limites para seus valores:

$[-V_{max}, V_{max}]$ (usualmente igual a X_{max})
limites do espaço de busca /2

O valor de **Vmax** deve ser alto o suficiente para as partículas passarem de um mínimo local, porém o desempenho pode não ser satisfatório se o valor escolhido de V_{max} não for apropriado.

Como controlar esta velocidade?

PSO

Métodos para controlar o crescimento da velocidade:

- ♦ Fator de ponderação de inércia - w
- ♦ Coeficiente de constrição - χ
- ♦ Uso de ambos concomitantemente - $\chi + w$

Os alunos usam concomitantemente há tempos...

$$\mathbf{v}(t+1) = \chi [w \mathbf{v}(t) + \phi_1 \text{rnd1}(\mathbf{p}_i - \mathbf{x}(t)) + \phi_2 \text{rnd2}(\mathbf{p}_g - \mathbf{x}(t))]$$

Kar, R.; Mandal, D.; Bardhan, S.; Ghoshal, S.P. Optimization of linear phase FIR band pass filter using particle swarm optimization with constriction factor and inertia weight approach. In Proceedings of the IEEE Symposium on Industrial Electronics and Applications (ICIEA), Langkawi, Malaysia, 25–28 September 2011; pp. 326–331.

PSO – Fator de inércia

Um fator de ponderação de inércia é introduzido na equação de movimento das partículas (Shi e Eberhart, 1998):

$$\mathbf{v}(t+1) = \omega \mathbf{v}(t) + \phi_1 \text{rnd1}(\mathbf{p}_i - \mathbf{x}(t)) + \phi_2 \text{rnd2}(\mathbf{p}_g - \mathbf{x}(t))$$

ω - valor constante (inicialmente)

Em 2000 os autores sugeriram:

- ω inicializado igual a 0.9 (melhor exploração do espaço) e decresce linearmente ao longo do tempo até 0.4

Este fator faz um balanceamento entre a busca local e global.

PSO – Coeficiente de Constrição

Em 1999, Maurice Clerc apresentou um coeficiente de constrição de forma a melhorar a convergência do método

$$\mathbf{v}(t+1) = \chi [\mathbf{v}(t) + \varphi_1 \text{rnd1}(\mathbf{p}_i - \mathbf{x}(t)) + \varphi_2 \text{rnd2}(\mathbf{p}_g - \mathbf{x}(t))]$$

$$\chi = \begin{cases} \frac{2\kappa}{\varphi - 2 + \sqrt{\varphi^2 - 4\varphi}} & \text{for } \varphi > 4 \\ \sqrt{\kappa} & \text{else} \end{cases}$$

Cria mais um
parâmetro: κ

$$\varphi = \varphi_1 + \varphi_2$$

PSO

Valores empregados por Clerc:

$$\kappa = 1$$

$$\varphi = 4.1$$

$$\Rightarrow \chi = 0.73$$

Tamanho de enxame = 20

Tamanho da vizinhança = 3

PSO - Estrutura social

O **termo social** envolve o melhor valor encontrado pela vizinhança de uma partícula.

A vizinhança corresponde a vizinhança topológica e não a vizinhança no espaço de atributos de cada partícula.

A vizinhança (ligação) entre as partículas, que é a forma em que umas partículas influenciam as outras, depende da topologia adotada. Ela é definida antes de se iniciar a busca.

Esta vizinhança pode ser toda a população ou parte dela.

PSO - Estrutura social

Dois princípios sociométricos: Local e Global

- ♦ **Global** – conecta todas as partículas da população.
A trajetória de cada partícula é influenciada pelo melhor ponto encontrado por qualquer membro de toda a população
- ♦ **Local** - cria uma vizinhança. Cada partícula é influenciada pelos membros adjacentes da população

As topologias podem ser:

- ♦ Em estrela
- ♦ Em roda
- ♦ Em círculo
- ♦ outras

Topologia em estrela


Modelo **Gbest** (Vizinhança Global)

Todas as partículas estão conectadas entre si.

A partícula com melhor desempenho é determinada a partir de todo o enxame.

O comportamento de cada partícula é influenciado pelo comportamento de todas as outras partículas.

Convergência tende a ser mais rápida, com risco de convergir para ótimo local.




Topologia em círculo

Modelo **Lbest** (Vizinhança Local)

A partícula é influenciada somente pelos seus k -vizinhos adjacentes ($k=2$)

Mais eficaz que a anterior em casos de convergência prematura.

A convergência pode ser mais lenta, mas permite uma exploração maior.




Topologia em roda



Uma partícula é vizinha de todas as demais, que são completamente isoladas entre si.

Esta partícula é chamada de "foco".

O desempenho da melhor partícula é transmitido ao foco que passa a influenciar as demais.



Outras topologias



Kennedy (1999) avaliou o impacto social empregando várias topologias de vizinhança.

Os resultados indicaram alguma melhora no desempenho, porém voltados para problemas específicos.

Outros trabalhos avaliaram os efeitos das topologias no comportamento da busca pelo PSO (Kennedy, 2002)

PSO - Dynamic Neighbourhood

- ◆ A vizinhança aumenta gradualmente a medida que a evolução progride, passando do modelo local, Lbest, para o modelo global, Gbest.
- ◆ As vizinhanças de fundem de acordo com regras pre-definidas até que o algoritmo atinja o modelo Gbest de vizinhança global.

Suganthan, P.N. Particle swarm optimiser with neighbourhood operator. In Proceedings of the Congress on Evolutionary Computation (CEC), Washington, WA, USA, 6–9 July 1999; Volume 3, pp. 1958–1962.

PSO – espaço busca

Partícula sai espaço de busca:

- Trazer partícula para o limite lateral mais próximo (há varias formas de trazer: por variável ou todo o vetor);
- Inverte (espelha) a posição da partícula em relação ao limite mais próximo ou espelhar só as variáveis que saíram do espaço de busca;
- Sortear nova velocidade e recalcular a posição;
- Inverter a velocidade e recalcular posição;
- Sorteia novo ponto interior espaço de busca;
- Etc.

PSO - Comentários

- ♦ PSO tem sido aplicado com sucesso em várias áreas de pesquisa.
- ♦ Alguns autores demonstraram que o PSO consegue melhores resultados de forma mais eficiente que outros métodos.
- ♦ O método é atraente porque são poucos os parâmetros que necessitam ser ajustados.
- ♦ Importante ajustar os parâmetros para que a partícula não saia com muita frequência do espaço de busca, gerando soluções candidatas inválidas. Medidas de correção podem ser adotadas.
- ♦ PSO Adaptativo – assim como outras heurísticas há também versões (auto) adaptativas dos parâmetros.

PSO - Hibridização com outras heurísticas

A hibridização do PSO com outros EA inclui

GA - genetic algorithm
SA - simulated annealing
DE – differential Evolution
ACO – ant colony optimization
ABC – Artificial Bee Colony
CS – Cuckoo search
BA – Bat algorithm
FA – Firefly Algorithm
GWSO – Glow Worm Swarm Optimization
AIS – Artificial Immune System
Etc.

Aplicações

- ♦ As primeiras aplicações de PSO foram na determinação de pesos e arquitetura de redes neurais artificiais.
- ♦ Aplicações a problemas de otimização de funções numéricas em geral, problema do caixeiro viajante, extração de regras de RN-Fuzzy, agrupamento de dados, classificação de imagens.
- ♦ Aplicações em problemas de mundo real (híbridos) como, diagnóstico médico, otimização de misturas de ingredientes para a indústria, geradores elétricos, desenvolvimento de fármacos.
- ♦ Problemas de otimização de engenharia com variáveis contínuas: sistemas de *risers* e de ancoragem de plataformas de petróleo flutuantes.

Sites interessantes

Softwares clássicos:

<http://www.swarmintelligence.org/SIBook/SI.php#Home>
<http://clerc.maurice.free.fr/psa/>

Livros

Swarm Intelligence
 by James Kennedy, Russell C. Eberhart, with Yuhui Shi
 Particle Swarm Optimization
 by Maurice Clerc

Artigos originários do PSO:

Kennedy, J., & Eberhart, R. C. (1995). Particle swarm optimization. In *Proceedings of the IEEE international Conference on neural networks IV* (pp. 1942–1948).

Kennedy, J. (1999). Small worlds and mega-minds: effects of neighborhood topology on particle swarm performance. In *Proceedings of the IEEE congress on evolutionary computation* (pp. 1931–1938).

Kennedy, J., & Mendes, R. (2002). Population structure and particle swarm performance. In *Proceedings of the IEEE congress on evolutionary computation (CEC)* (pp. 1671–1676)

Recent Reviews

<https://ieeexplore.ieee.org/document/9680690>

(Shami et al. *IEEE Access*, vol. 10, pp. 10031-10061, **2022**)

<https://link.springer.com/article/10.1007/s11831-021-09694-4>

(Gad, *Archives of Comp. Methods in Engineering* 29:2531–2561, **2022**)

<https://doi.org/10.3390/e22030362>

(Freitas et al. *Entropy* **2020**, 22(3), 362)

<https://doi.org/10.3390/make1010010>

(Sengupta et al. *Mach. Learn. Knowl. Extr.* **2019**, 1(1), 157-191)

https://www.mitpressjournals.org/doi/pdf/10.1162/EVCO_r_00180

(**2016 – Bonyadi e Michalewicz**)

<https://link.springer.com/article/10.1007/s00500-016-2474-6>

(**2017 - Wang et al.**)

Atenção: importante acompanhar a literatura, as variantes dos algoritmos, lendo publicações em congressos e revistas de alto impacto na área.