


AG Clássico ou AG Simples (AGS)

- ◆ Representação Binária
- ◆ População de tamanho fixo
- ◆ Reprodução com substituição da população
- ◆ Seleção natural proporcional a aptidão via método da roleta
- ◆ *Cruzamento* simples - 1 ponto
- ◆ Mutação pontual



O processo de busca no AG

As técnicas evolutivas de busca global caracterizam-se pela capacidade de explorar regiões do espaço de busca.

Utilizam 2 princípios: **exploration** e **exploitation** [Holland,1975]

- **Exploração** - capacidade de visitar pontos desconhecidos no espaço de busca a procura de novas soluções.
 - **Exploração** – capacidade de retirar informações presentes nas soluções encontradas.
-
- Técnicas de busca puramente aleatórias empregam **exploração**.
 - Métodos de subida de encosta utilizam **exploração**.

O processo de busca no AG

Nos AGs a **seleção** dirige a busca aos melhores pontos do espaço (**exploração**).

A **pressão de seleção** influencia na quantidade de **exploração** e **exploração**.

Pressão de seleção = Aptidão máx da pop / Aptidão média

➤ Quando **pressão de seleção** é muito baixa (aptidão é quase a mesma para toda a população) o AG assume comportamento aleatório (**exploração**).

➤ Quando **pressão de seleção** é muito alta, o AG assume comportamento dos métodos de subida de encosta (**exploração**)

Na prática é difícil conhecer qual **pressão de seleção** fornece o equilíbrio ideal.

O processo de busca no AG

O **cruzamento** é o principal mecanismo de busca do AG:

É capaz de combinar as boas porções dos cromossomos pais (blocos de construção).

Resulta na produção de filhos com aptidões mais elevadas que as dos pais.

A **mutação** também tem função importante no AG:

Permite que qualquer ponto de busca seja alcançado.

O AG usa o **cruzamento** como mecanismo de **exploração** e a **mutação** como mecanismo de **exploração**.

Embora os AGs empreguem ambas abordagens, alguns problemas surgem na prática.

Problemas de Convergência

AGs podem encontrar problemas para chegar a solução ótima.

Convergência prematura ou convergência muito lenta

Problemas de convergência prematura surgem quando existem na população indivíduos com a **aptidão muito acima da aptidão média**:

Superindivíduos

- Geram um número muito grande de filhos.
- Genes dos superindivíduos passam a ser dominantes na população, enquanto outros desaparecem em consequência disto.

Problemas de Convergência

A **seleção** descarta muitos cromossomos com aptidão baixa, eliminando assim muitos genes.

O desaparecimento de determinados genes impossibilita o AG de explorar completamente o espaço de busca → pode convergir para um ótimo local.

O desaparecimento de genes ao longo das gerações é conhecido na biologia como **genetic drift**.

- A **mutação** permite recuperar genes descartados, pois o **cruzamento** não gera novos genes, apenas combina os que já existem.
- Com taxas adequadas de mutação é possível manter uma boa diversidade da população contrabalanceando estas perdas de genes.

Problemas de Convergência

A convergência prematura pode ser evitada:

- Limitando-se o número de filhos por cromossomo
- Garantindo-se a diversidade da população

Maneiras de melhorar a diversidade na população:

- ✓ Aumentando a taxa de mutação (a mutação é responsável pela criação de mais genes).
- ✓ Uso de cruzamento uniforme.
- ✓ Evitando que duplicatas de cromossomos sejam inseridas na população.
- ✓ Estratégias de cruzamento alternativas, tais como: prevenção de incestos

Problemas de Convergência

Problemas de convergência associados ao mecanismo de seleção:

Muitas vezes provocados porque o **valor da função objetivo** é usado como **medida da aptidão**.

Técnicas de mapeamento da função objetivo.

Problemas de Convergência

Nem sempre a função objetivo é adequada para ser usada como Aptidão.

A função objetivo pode assumir:

Valores negativos $\Rightarrow$ Roda da roleta não funciona

Valores muito próximos $\Rightarrow$ Tornam a seleção aleatória

Valores muito altos em relação ao resto da população, em locais que não sejam a região ótima $\Rightarrow$ Causa convergência prematura

A função objetivo pode ser mapeada de várias formas:

Ranking

Escalonamento Linear

Windowing

Mapeamento da Função Objetivo: **Ranking**

Ordenamento Linear

- Indivíduos são classificados e ordenados em função de uma nota (lista ordenada de acordo com a aptidão)
- Ao cromossomo de maior aptidão (o primeiro do *rank*), é associado um número arbitrário *Max*
- Ao cromossomo de menor aptidão é associado o número *Min*
- O resto da população recebe a sua posição interpolando-se estes valores extremos:

$$f_i = Min + (Max - Min) \frac{(N - i)}{(N - 1)}$$

N - tamanho da população
 i - *rank*, de acordo com a aptidão
 f_i - situação do indivíduo no *rank*

Usual:

$$1 \leq Max \leq 2 \quad \text{e} \quad (Max + Min) = 2$$

Mapeamento da função objetivo: *Ranking*

Exemplo:

O valor da função objetivo é praticamente o mesmo para toda a população.

O método expande o intervalo entre estes valores.

Cromossomo	Função objetivo	Rank	Aptidão f_i
A	1000,998	1	2.0
B	1000,827	2	1.5
C	1000,656	3	1.0
D	1000,421	4	0.5
E	1000,102	5	0.0

Max-Min determina a pressão de seleção ($f_{\max}/f_{\text{med}}$)

a aptidão representa o número de filhos esperados

$$f_i = \text{Min} + (\text{Max} - \text{Min}) \frac{(N-i)}{(N-1)}$$

$$f_i = 2 \frac{(N-i)}{(N-1)}$$

Aptidão em taxa constante para todos.

O valor da função objetivo serviu apenas para determinar a ordem dos indivíduos, e a aptidão não tem mais relação com a avaliação original.


Mapeamento da função objetivo: *Ranking*

A **alta pressão de seleção**

favorece melhores indivíduos $\Rightarrow$ direciona a busca para as melhores soluções já encontradas (muita exploração) $\Rightarrow$ vai perdendo a diversidade

A **baixa pressão de seleção**


favorece indivíduos de baixa aptidão $\Rightarrow$ direciona a busca para regiões desconhecidas (muita exploração)



Mapeamento da função objetivo: *Ranking*


Neste exemplo, há um superindivíduo que provavelmente dominaria a população da 2ª geração.

Ind	f_i	$f_i/\Sigma f$
A	1000	0.75
B	90	0.07
C	22	0.02
D	15	0.01
E	200	0.15



Outra forma de normalização linear: atribuir ao pior indivíduo **fit = 1** e ao melhor **fit = N**

Ind	Rank	f_i
A	1	5.0
B	3	3.0
C	4	2.0
D	5	1.0
E	2	4.0



Agora, todos os indivíduos tem chance de serem escolhidos.

Este método pode aumentar o tempo de convergência, pois os indivíduos não diferem muito uns dos outros (baixa pressão de seleção).

Mapeamento da função objetivo: *Ranking*

Ranking exponencial : mantém a pressão de seleção num nível maior

$$P_{exp-rank}(i) = \frac{1 - e^{-i}}{c}$$

Melhor indivíduo com $fit = N$ e o pior com $fit = 1$

Constante c é função do tamanho da população.

Mapeamento da função objetivo: *Ranking*

O uso de *ranking* permite algum controle da pressão de seleção, o que não é possível com a reprodução proporcional a aptidão.


Este método foi criticado justamente por dissociar essencialmente a aptidão da função objetivo. [Goldberg]

Michalewicz [1999] apresenta outros métodos baseados em *ranking* utilizando parâmetros definidos pelo usuário.

Mapeamento da função objetivo: Escalonamento Linear

A aptidão é obtida por:

$$f = a \cdot g + b$$



g – valor da função objetivo

Coefficientes a e b são calculados de forma a:

- $f_{\text{méd}} = g_{\text{méd}}$
- controlar o número de filhos do membro com maior valor da função objetivo, evitando a perda de diversidade.

$$f_{\max} = C \cdot f_{\text{méd}}$$

Tipicamente C varia de 1.2 a 2 (para n_{pop} entre 50 e 100)

Quando o escalonamento gerar aptidões negativas, os coeficientes a e b devem ser calculados impondo-se $f_{\min} = 0$

Mapeamento da função objetivo

Outro problema:

Surgimento de um grupo de indivíduos com **avaliações muito baixas**.

Tais indivíduos terão pequena probabilidade de serem escolhidos para gerar descendentes:

- É importante que eles gerem descendentes, pois eles são a fonte da diversidade das soluções.
- Se exterminados logo no início, a população rapidamente tenderá para uma **convergência precoce**: ótimo local.

A correção para este problema pode ser a **técnica de *Windowing*** (janelamento):

Determina-se um valor mínimo de aptidão que é atribuído a todos aqueles que ficarem abaixo de um certo piso na avaliação.

Mapeamento da função objetivo

◆ **Windowing**

Técnica para impulsionar a aptidão dos indivíduos mais fracos de forma a prevenir a eliminação destes e a dominância de um pequeno grupo de cromossomos.

- Obtenha a avaliação mínima na população $A_{\min}$.
- Atribua a cada cromossomo i uma aptidão que representa a quantidade que ela excede o mínimo:
$$A_i = (f_i - A_{\min})$$
- Opcionalmente, atribua uma quantidade mínima de "sobrevivência" maior que a mínima calculada, como garantia de reprodução para os cromossomos menos aptos.

Medidas de Desempenho

Para quantificar a eficiência de diferentes AGs ao longo da execução *De Jong* (1975) empregou duas medidas:

- **On-line**
- **Off-line**

- A medida *On-line* premia a rápida obtenção de boas soluções
- A medida *Off-line* premia melhores soluções, independente do tempo necessário para encontrá-las.

Medidas de Desempenho

$$Mo(t) = 1 / T \sum_1^T f_e(t)$$

- **On-line:** $f_e(t)$ valor da função objetivo dos indivíduos na iteração t
(Mo é a média das avaliações de todos indivíduos até a iter. t)
- **Off-line:** $f_e(t)$ valor da função objetivo dos melhores indivíduos
(Mo é a média das avaliações dos melhores indivíduos encontrados em cada iteração até a iter. t)

Desempenho x Convergência


Critérios de parada

- Se o valor ótimo é conhecido: a parada é determinada assim que o algoritmo atingir este valor durante o processo de evolução
- Interromper o algoritmo assim que ele atinja um número pré-determinado de gerações (este é o mais simples deles).
- Parar o processo quando uma ou mais condições forem satisfeitas:
 - não houver melhora no valor da aptidão do melhor indivíduo ou da média das aptidões, para algumas gerações consecutivas
 - a média das aptidões se aproximar da aptidão do melhor indivíduo
 - a variedade genética for menor que um limite mínimo estabelecido

Desempenho x Convergência: Exemplo

Critério de proximidade: média da aptidão dos indivíduos e a aptidão do melhor indivíduo.

Exemplo: interrupção da evolução do algoritmo quando a diferença entre média e melhor permanecer $\leq 2\%$ durante no mínimo **5 gerações**.



AG Tradicional

Problemas com o algoritmo clássico:

- ◆ o princípio de reprodução/seleção permite a perda do melhor indivíduo
- ◆ a posição dos genes no cromossomo influi na probabilidade de permanecerem no mesmo cromossomo após *cruzamento*
- ◆ dificuldades na codificação binária de números reais

Algumas estratégias de solução:

- ◆ mecanismos alternativos de seleção
- ◆ *cruzamento* uniforme
- ◆ codificação em arranjos de números reais

Algumas Modificações no AG tradicional

População inicial

- Gerando-se uma população inicial maior que as seguintes, pode-se melhorar a representação do espaço de busca.
Se uma população inicial pequena for gerada aleatoriamente pode-se não representar algumas regiões deste espaço.
- Alternativa para melhorar a exploração do espaço de busca
 - gerar uma metade da população inicial aleatoriamente, e a outra metade a partir da primeira: invertendo-se os bits. Cada posição na cadeia de bits terá um representante na população com os valores 0 e 1.
 - Técnica conhecida como **seeding** :
Caso se conheça alguma solução anterior do problema, introduzi-la na população inicial, garantindo que a solução encontrada nunca seja pior que a existente.

Substituições **geracional** e **steady-state**

Procedimentos mais comuns para substituição de cromossomos:

- ◆ **Geracional:** substitui toda a população em cada geração.
Pode se adotar um critério de **seleção elitista**, onde os **k** melhores pais nunca são substituídos. Geralmente faz-se **k=1** para evitar problemas de convergência prematura.
- ◆ **Steady-state:** gera apenas um ou dois filhos por vez que substituem um ou dois piores cromossomos da população.
Alternativas:
 1. Os 2 filhos podem substituir os 2 indivíduos mais velhos da população (supõe-se que um cromossomo antigo já transmitiu seus genes para a população).
 2. Só insere indivíduo na população se ele possuir aptidão maior que a aptidão média da população.

Substituições **geracional** e **steady-state**

- ◆ Em geral, a taxa de cruzamento é maior (≈ 1) no AG *steady-state* que no geracional.
- ◆ Na forma geral do AG *steady-state*, são criados n filhos que substituem os n piores pais.
- ◆ A substituição *steady-state* já disponibiliza os indivíduos para a reprodução assim que são gerados : **não há população intermediária**.
Isto tem promovido bons resultados, contudo, gera um custo computacional extra, pois para cada filho criado é necessário reordenar a população, recalculando a aptidão média e dados estatísticos.

Codificação: binária x real

Na **representação binária** não existe uniformidade nos operadores:
Mutações nos primeiros bits do gene afetam mais a aptidão
que mutação nos últimos bits do gene.

Na **codificação binária**: dois pontos vizinhos na representação do espaço
de busca de uma variável real nem sempre os torna vizinhos também
na codificação.

Por exemplo:

Passar do valor real 7 (**0111**) em binário, para 8 (**1000**)
→ necessário trocar todos os bits da cadeia.

Código Gray - também usa uma representação binária, contudo, torna
pontos vizinhos no espaço de busca também vizinhos na codificação.

Codificação binária e distância de Hamming* entre cromossomos consecutivos formados por 4 genes

Inteiro	Binário	Dist. de Hamming	Inteiro	Binário	Dist. de Hamming
0	0000	-	8	1000	4
1	0001	1	9	1001	1
2	0010	2	10	1010	2
3	0011	1	11	1011	1
4	0100	3	12	1100	3
5	0101	1	13	1101	1
6	0110	2	14	1110	2
7	0111	1	15	1111	1

* Quantidade de caracteres que precisam ser mudados em uma sequência
para se obter a outra

Codificação de Gray e distância de Hamming* entre cromossomos consecutivos formados por 4 genes

Inteiro	Código Gray	Dist. de Hamming	Inteiro	Código Gray	Dist. de Hamming
0	0000	-	8	1100	1
1	0001	1	9	1101	1
2	0011	1	10	1111	1
3	0010	1	11	1110	1
4	0110	1	12	1010	1
5	0111	1	13	1011	1
6	0101	1	14	1001	1
7	0100	1	15	1000	1

* Distância de Hamming entre dois cromossomos que representem valores adjacentes no espaço de busca é sempre 1

Procedimento para converter codificação binária em Gray

Para uma cadeia de 4 bits:

◆ Para código de Gray:

$$x_g = A \cdot x_b$$

$$A = \begin{vmatrix} 1 & 1 & 0 & 0 \\ 0 & 1 & 1 & 0 \\ 0 & 0 & 1 & 1 \\ 0 & 0 & 0 & 1 \end{vmatrix}$$

◆ Para código binário:

$$x_b = A^{-1} \cdot x_g$$

$$A^{-1} = \begin{vmatrix} 1 & 1 & 1 & 1 \\ 0 & 1 & 1 & 1 \\ 0 & 0 & 1 & 1 \\ 0 & 0 & 0 & 1 \end{vmatrix}$$

Representação Real

Naturalmente compreendida → Não necessita de codificações e decodificações

A **codificação real** é mais eficiente ao empregar variáveis contínuas que necessitem de alta precisão → representação binária resulta em cromossomos muito longos.

Necessidade de criar **novos operadores** e variações dos operadores existentes.

Operadores tendem a ser mais específicos à aplicação.

Representação Real

Operadores **cruzamento** usados para codificações binárias não têm um bom desempenho para codificações reais:

Apenas trocam valores dos parâmetros, e não criam informação nova.

Recomenda-se a utilização de **operadores aritméticos** ou baseados em direção, quando se usa codificação real.

Cromossomos pais: mãe = $(m_1, m_2, \dots, m_i)$

pai = $(p_1, p_2, \dots, p_i)$

Cromossomo filho : filho = $(a_1, a_2, \dots, a_i)$

Representação Real

Operadores aritméticos:

Se baseiam em conceitos de combinação linear de vetores.

Mais comuns (geram apenas um filho):

- **cruzamento média:** $a_i = (m_i + p_i) / 2$

- **cruzamento média geométrica:** $a_i = \sqrt{m_i p_i}$

Representação Real

- **cruzamentos de n -pontos e uniformes**
da codificação binária podem ser utilizados na
codificação real, com uma modificação:

$$a_i = \lambda m_i + (1 - \lambda) p_i$$

λ é um número aleatório escolhido na distribuição uniforme no intervalo $[0,1]$

O segundo filho é gerado trocando-se os coeficientes de m_i e p_i
(este operador é mais interessante pois pode gerar 2 filhos).

λ pode também ser função da geração t (depende da idade da população)

Muitos outros operadores de cruzamento podem ser encontrados na literatura.

Representação Real

Existem vários operadores de mutação, dentre eles:

Mutação aleatória - simples substituição de um gene (que tenha passado no teste de probabilidade) por um número escolhido aleatoriamente num intervalo definido pelo problema.

pai: (p_1, p_2, p_3) $\Rightarrow$ filho: $(p_1, p_{\text{aleat}}, p_3)$

Mutação *creep* - adiciona ao gene um pequeno número aleatório obtido de uma distribuição normal (com média zero e desvio pequeno) ou de uma distribuição uniforme

pai: (p_1, p_2, p_3) $\Rightarrow$ filho: $(p_1 + \sigma_1, p_2 + \sigma_2, p_3 + \sigma_3)$

Representação Real x Binária

Resumo:

1. Naturalmente compreendida: Não necessita de codificações
2. A representação real é mais eficiente para problemas em domínio contínuo
3. A representação real é mais eficiente para problemas que necessitem de alta precisão (binária $\rightarrow$ cromossomos muito longos).
4. O desempenho com representação real pode ser melhorado com operadores específicos à aplicação.
5. Os indivíduos estão mais próximos do espaço do problema, já que dois pontos próximos um ao outro no espaço de representação, estão também próximos no espaço do problema.
6. A execução costuma ser mais rápida e com maior precisão na representação real

Referências

- ◆ Michalewicz, Z., Genetic Algorithms + Data Structures = Evolution Programs, Springer, 1999.
- ◆ Holland, J.H., Adaptation in Natural and Artificial Systems, MIT, 1975.
- ◆ Coello A.A.C., An Empirical Study of Evolutionary Techniques for Multiobjective Optimization in Engineering Design, Tulane University, 1996
- ◆ Lacerda, E. G. M., de Carvalho, A. C. P. L. F., Data, "Introdução aos Algoritmos Genéticos". In: Anais do XIX Congresso Nacional da Sociedade Brasileira de Computação, pp.51-126, RJ, 1999.